Andre marroquin 22266

Librerias importarlas

In [ ]:
```
# imports de las librerias principales
import os
import re
import math
import json
import time
import hashlib
import warnings
from itertools import combinations
import numpy as np
import pandas as pd
import pefile
import networkx as nx
import matplotlib.pyplot as plt
from sklearn.preprocessing import StandardScaler
from sklearn.compose import ColumnTransformer
from sklearn.pipeline import Pipeline
from sklearn.feature_extraction.text import TfidfVectorizer
from sklearn.decomposition import PCA, TruncatedSVD
from sklearn.cluster import KMeans
from sklearn.metrics import silhouette_score, silhouette_samples
from sklearn_extra.cluster import KMedoids
from google import genai
from google.genai import types

warnings.filterwarnings("ignore")
pd.set_option("display.max_columns", None)
pd.set_option("display.max_colwidth", 120)
```

rutas principales

In [ ]:
```
# se definen las rutas para salidas y entrads
RutaDataset = "./MALWR"
RutaSalida = "./salidasLab3"
RutaGraficas = os.path.join(RutaSalida, "graficas")
RutaGrafos = os.path.join(RutaSalida, "grafos")
RutaTablas = os.path.join(RutaSalida, "tablas")

os.makedirs(RutaSalida, exist_ok=True)
os.makedirs(RutaGraficas, exist_ok=True)
os.makedirs(RutaGrafos, exist_ok=True)
os.makedirs(RutaTablas, exist_ok=True)

ListaUmbrales = [0.60, 0.80, 0.95]
```

```
RangoK = list(range(2, 11))
Semilla = 42
LongitudMinimaString = 4
MaxStringsDocumento = 250
MaxFuncionesDocumento = 200
MaxDllDocumento = 80
MaxSeccionesDocumento = 20
ModeloGeminiEmbeddings = "gemini-embedding-001"

print("Ruta dataset:", RutaDataset)
print("Ruta salida:", RutaSalida)
```

```
Ruta dataset: ./MALWR
Ruta salida: ./salidasLab3
```

Funciones base para validacion entropia hashing y similitud

In [ ]:

```
# si el archivo puede ser un PE por cabecera MZ
def esEjecutablePe(rutaArchivo: str) -> bool:
    try:
        with open(rutaArchivo, "rb") as archivo:
            cabecera = archivo.read(2)
        return cabecera == b"MZ"
    except Exception:
        return False


# entropia de Shannon de un bloque de bytes
def calcularEntropiaBytes(datos: bytes) -> float:
    if not datos:
        return 0.0
    arreglo = np.frombuffer(datos, dtype=np.uint8)
    conteos = np.bincount(arreglo, minlength=256)
    probabilidades = conteos / len(arreglo)
    probabilidades = probabilidades[probabilidades > 0]
    return float(-(probabilidades * np.log2(probabilidades)).sum())


# convierte lista de tokens a conjunto limpio
def listaAConjunto(listaValores: list[str]) -> set[str]:
    salida = set()
    for valor in listaValores:
        if valor is None:
            continue
        token = str(valor).strip().lower()
        if token:
            salida.add(token)
    return salida


# calcula indice de Jaccard entre dos conjuntos
def jaccardConjuntos(conjuntoA: set[str], conjuntoB: set[str]) -> float:
    if not conjuntoA and not conjuntoB:
```

```
        return 1.0
    if not conjuntoA or not conjuntoB:
        return 0.0
    interseccion = len(conjuntoA.intersection(conjuntoB))
    union = len(conjuntoA.union(conjuntoB))
    if union == 0:
        return 0.0
    return float(interseccion / union)


# jala el hash sha256 del archivo para identificarlo
def calcularSha256Archivo(rutaArchivo: str) -> str:
    try:
        hashSha256 = hashlib.sha256()
        with open(rutaArchivo, "rb") as archivo:
            for bloque in iter(lambda: archivo.read(1024 * 1024), b""):
                hashSha256.update(bloque)
        return hashSha256.hexdigest()
    except Exception:
        return ""


# extrae strings ASCII imprimibles desde bytes del binario
def extraerStringsBinario(rutaArchivo: str, longitudMinima: int = 4) -> list
    try:
        with open(rutaArchivo, "rb") as archivo:
            datos = archivo.read()
        patron = rb"[ -~]{" + str(longitudMinima).encode() + rb",}"
        encontrados = re.findall(patron, datos)
        stringsLimpios = []
        for valor in encontrados:
            try:
                texto = valor.decode("utf-8", errors="ignore").strip().lower
                if texto:
                    stringsLimpios.append(texto)
            except Exception:
                continue
        return stringsLimpios
    except Exception:
        return []


#  empaquetado de forma heuristica por nombres y entropia
def estaEmpaquetadoHeuristico(rutaArchivo: str, umbralEntropia: float = 7.2)
    try:
        pe = pefile.PE(rutaArchivo, fast_load=True)
        nombresSospechosos = {"upx", "aspack", "fsg", "mpress", "petite", "t
        totalSecciones = 0
        seccionesAltas = 0
        banderaNombre = False

        for seccion in getattr(pe, "sections", []):
            totalSecciones += 1
            nombre = seccion.Name.decode(errors="ignore").strip("\x00").lowe
            if any(valor in nombre for valor in nombresSospechosos):
                banderaNombre = True
```

```
            datos = seccion.get_data() or b""
            entropia = calcularEntropiaBytes(datos)
            if entropia >= umbralEntropia:
                seccionesAltas += 1

        pe.close()

        if banderaNombre:
            return True
        if totalSecciones > 0 and (seccionesAltas / totalSecciones) >= 0.5:
            return True
        return False
    except Exception:
        return False
```

Funciones para extraccion de metadatos PE y construccion del dataset

In [ ]:
```
# saca toda metadata PE, imports, dlls y secciones sin ejecutar el archivo
def extraerMetadatosPe(rutaArchivo: str) -> dict:
    resultado = {
        "esPe": False,
        "tamanoBytes": 0,
        "sha256": "",
        "machine": "",
        "compiladoEpoch": 0,
        "numeroSecciones": 0,
        "entryPoint": 0,
        "imageBase": 0,
        "subsystem": 0,
        "dll": 0,
        "aslr": 0,
        "dep": 0,
        "numeroImports": 0,
        "numeroDlls": 0,
        "numeroExports": 0,
        "numeroRecursos": 0,
        "numeroStrings": 0,
        "entropiaArchivo": 0.0,
        "entropiaPromedioSecciones": 0.0,
        "empaquetadoHeuristico": 0,
        "seccionesTexto": "",
        "dllsTexto": "",
        "funcionesTexto": "",
    }

    try:
        resultado["tamanoBytes"] = os.path.getsize(rutaArchivo)
    except Exception:
        resultado["tamanoBytes"] = 0
```

```
    resultado["sha256"] = calcularSha256Archivo(rutaArchivo)

    try:
        with open(rutaArchivo, "rb") as archivo:
            datosArchivo = archivo.read()
        resultado["entropiaArchivo"] = calcularEntropiaBytes(datosArchivo)
    except Exception:
        resultado["entropiaArchivo"] = 0.0

    if not esEjecutablePe(rutaArchivo):
        return resultado

    try:
        pe = pefile.PE(rutaArchivo, fast_load=False)
        resultado["esPe"] = True
        resultado["machine"] = hex(int(pe.FILE_HEADER.Machine))
        resultado["compiladoEpoch"] = int(pe.FILE_HEADER.TimeDateStamp)
        resultado["numeroSecciones"] = int(pe.FILE_HEADER.NumberOfSections)
        resultado["entryPoint"] = int(pe.OPTIONAL_HEADER.AddressOfEntryPoint
        resultado["imageBase"] = int(pe.OPTIONAL_HEADER.ImageBase)
        resultado["subsystem"] = int(pe.OPTIONAL_HEADER.Subsystem)
        resultado["dll"] = int(bool(pe.FILE_HEADER.Characteristics & 0x2000)
        resultado["aslr"] = int(bool(pe.OPTIONAL_HEADER.DllCharacteristics &
        resultado["dep"] = int(bool(pe.OPTIONAL_HEADER.DllCharacteristics &
        resultado["empaquetadoHeuristico"] = int(estaEmpaquetadoHeuristico(r

        listaSecciones = []
        listaEntropias = []

        for seccion in getattr(pe, "sections", []):
            nombreSeccion = seccion.Name.decode(errors="ignore").strip("\x00
            if nombreSeccion:
                listaSecciones.append(nombreSeccion)
            datosSeccion = seccion.get_data() or b""
            listaEntropias.append(calcularEntropiaBytes(datosSeccion))

        if listaEntropias:
            resultado["entropiaPromedioSecciones"] = float(np.mean(listaEntr
        resultado["seccionesTexto"] = " ".join(sorted(set(listaSecciones))[:

        listaDlls = []
        listaFunciones = []

        pe.parse_data_directories(
            directories=[
                pefile.DIRECTORY_ENTRY["IMAGE_DIRECTORY_ENTRY_IMPORT"],
                pefile.DIRECTORY_ENTRY["IMAGE_DIRECTORY_ENTRY_EXPORT"],
                pefile.DIRECTORY_ENTRY["IMAGE_DIRECTORY_ENTRY_RESOURCE"],
            ]
        )

        if hasattr(pe, "DIRECTORY_ENTRY_IMPORT"):
            for entrada in pe.DIRECTORY_ENTRY_IMPORT:
                nombreDll = entrada.dll.decode(errors="ignore").lower() if e
                if nombreDll:
                    listaDlls.append(nombreDll)
```

```
                for funcion in entrada.imports:
                    if funcion.name:
                        nombreFuncion = funcion.name.decode(errors="ignore")
                        listaFunciones.append(f"{nombreDll}:{nombreFuncion}"

        resultado["numeroImports"] = int(len(listaFunciones))
        resultado["numeroDlls"] = int(len(set(listaDlls)))
        resultado["dllsTexto"] = " ".join(sorted(set(listaDlls))[:MaxDllDocu
        resultado["funcionesTexto"] = " ".join(sorted(set(listaFunciones))[:

        if hasattr(pe, "DIRECTORY_ENTRY_EXPORT") and getattr(pe, "DIRECTORY_
            simbolos = getattr(pe.DIRECTORY_ENTRY_EXPORT, "symbols", [])
            resultado["numeroExports"] = int(len(simbolos))

        if hasattr(pe, "DIRECTORY_ENTRY_RESOURCE") and getattr(pe, "DIRECTOR
            try:
                resultado["numeroRecursos"] = int(len(pe.DIRECTORY_ENTRY_RES
            except Exception:
                resultado["numeroRecursos"] = 0

        pe.close()
        return resultado

    except Exception:
        return resultado


# crea doc a partir de strings e imports para NLP y embeddings
def construirDocumentoAnalisis(stringsLista: list[str], funcionesLista: list
    stringsTop = stringsLista[:MaxStringsDocumento]
    funcionesTop = funcionesLista[:MaxFuncionesDocumento]
    partes = [
        "strings " + " ".join(stringsTop),
        "funciones " + " ".join(funcionesTop),
        "dlls " + str(dllsTexto),
        "secciones " + str(seccionesTexto),
    ]
    documento = " ".join(partes).strip().lower()
    documento = re.sub(r"\s+", " ", documento)
    return documento


# recorre el dataset y arma un dataframe completo para clustering y similitu
def construirDatasetMalware(rutaDataset: str, longitudMinimaString: int = 4)
    filas = []

    for raiz, _, archivos in os.walk(rutaDataset):
        for nombreArchivo in sorted(archivos):
            rutaArchivo = os.path.join(raiz, nombreArchivo)

            if not os.path.isfile(rutaArchivo):
                continue

            if not esEjecutablePe(rutaArchivo):
                continue
```

```
            metadatos = extraerMetadatosPe(rutaArchivo)
            stringsLista = extraerStringsBinario(rutaArchivo, longitudMinima

            funcionesLista = []
            if metadatos["funcionesTexto"]:
                funcionesLista = metadatos["funcionesTexto"].split()

            documentoAnalisis = construirDocumentoAnalisis(
                stringsLista=stringsLista,
                funcionesLista=funcionesLista,
                dllsTexto=metadatos["dllsTexto"],
                seccionesTexto=metadatos["seccionesTexto"],
            )

            fila = {
                "rutaArchivo": rutaArchivo,
                "nombreArchivo": nombreArchivo,
                "sha256": metadatos["sha256"],
                "tamanoBytes": metadatos["tamanoBytes"],
                "esPe": int(metadatos["esPe"]),
                "machine": metadatos["machine"],
                "compiladoEpoch": metadatos["compiladoEpoch"],
                "numeroSecciones": metadatos["numeroSecciones"],
                "entryPoint": metadatos["entryPoint"],
                "imageBase": metadatos["imageBase"],
                "subsystem": metadatos["subsystem"],
                "dll": metadatos["dll"],
                "aslr": metadatos["aslr"],
                "dep": metadatos["dep"],
                "numeroImports": metadatos["numeroImports"],
                "numeroDlls": metadatos["numeroDlls"],
                "numeroExports": metadatos["numeroExports"],
                "numeroRecursos": metadatos["numeroRecursos"],
                "numeroStrings": len(stringsLista),
                "entropiaArchivo": metadatos["entropiaArchivo"],
                "entropiaPromedioSecciones": metadatos["entropiaPromedioSecc
                "empaquetadoHeuristico": metadatos["empaquetadoHeuristico"],
                "seccionesTexto": metadatos["seccionesTexto"],
                "dllsTexto": metadatos["dllsTexto"],
                "funcionesTexto": metadatos["funcionesTexto"],
                "stringsTexto": " ".join(stringsLista[:MaxStringsDocumento])
                "documentoAnalisis": documentoAnalisis,
            }
            filas.append(fila)

    dataframe = pd.DataFrame(filas)
    if not dataframe.empty:
        dataframe = dataframe.sort_values(["nombreArchivo"]).reset_index(drc
    return dataframe
```

Creacion y guardado del dataset de malware

In [ ]:
```
# se crea el dataset y se guarda
DfDataset = construirDatasetMalware(RutaDataset, longitudMinimaString=Longit

RutaCsvDataset = os.path.join(RutaTablas, "datasetMalware.csv")
DfDataset.to_csv(RutaCsvDataset, index=False, encoding="utf-8")

print("Total de muestras:", len(DfDataset))
print("Dataset guardado en:", RutaCsvDataset)
DfDataset.head(10)
```

```
Total de muestras: 40
Dataset guardado en: ./salidasLab3/tablas/datasetMalware.csv
```

Out[ ]:

	rutaArchivo	
0	./MALWR/1F2EB7B090018D975E6D9B40868C94CA	1F2EB7B090018D975E
1	./MALWR/33DE5067A433A6EC5C328067DC18EC37	33DE5067A433A6EC5C
2	./MALWR/65018CD542145A3792BA09985734C12A	65018CD542145A3792
3	./MALWR/650A6FCA433EE243391E4B4C11F09438	650A6FCA433EE24339
4	./MALWR/6FAA4740F99408D4D2DDDD0B09BBDEFD	6FAA4740F99408D4D2D
5	./MALWR/785003A405BC7A4EBCBB21DDB757BF3F	785003A405BC7A4EBC

	rutaArchivo	
6	./MALWR/8442AE37B91F279A9F06DE4C60B286A3	8442AE37B91F279A9F
7	./MALWR/99A39866A657A10949FCB6D634BB30D5	99A39866A657A10949
8	./MALWR/A316D5AECA269CA865077E7FFF356E7D	A316D5AECA269CA865
9	./MALWR/AAAz2E1B6940985A23E5639450F8391820655	AAAz2E1B6940985A23E5639

Exploracion inicial de dataset

In [ ]:
```
# Eda para entender el dataset antes del clustering
def resumirDataset(dataframe: pd.DataFrame) -> pd.DataFrame:
    filas = []

    for columna in dataframe.columns:
        serie = dataframe[columna]
        fila = {
            "columna": columna,
            "tipo": str(serie.dtype),
            "nulos": int(serie.isna().sum()),
            "unicos": int(serie.nunique(dropna=True)),
        }

        if pd.api.types.is_numeric_dtype(serie):
            fila["min"] = float(serie.min()) if len(serie) else 0.0
            fila["max"] = float(serie.max()) if len(serie) else 0.0
            fila["media"] = float(serie.mean()) if len(serie) else 0.0
        else:
            fila["min"] = None
            fila["max"] = None
            fila["media"] = None

        filas.append(fila)

    return pd.DataFrame(filas)


# crea columnas auxiliares para preprocesamiento y analisis
def enriquecerDataset(dataframe: pd.DataFrame) -> pd.DataFrame:
    copia = dataframe.copy()

    copia["logTamanoBytes"] = np.log1p(copia["tamanoBytes"])
    copia["logNumeroStrings"] = np.log1p(copia["numeroStrings"])
    copia["logNumeroImports"] = np.log1p(copia["numeroImports"])
    copia["logNumeroDlls"] = np.log1p(copia["numeroDlls"])
    copia["logNumeroSecciones"] = np.log1p(copia["numeroSecciones"])
    copia["textoCabecera"] = (
        "machine " + copia["machine"].astype(str) + " " +
        "subsystem " + copia["subsystem"].astype(str) + " " +
        "dll " + copia["dll"].astype(str) + " " +
        "aslr " + copia["aslr"].astype(str) + " " +
        "dep " + copia["dep"].astype(str)
    )
    copia["documentoCompleto"] = (
        copia["documentoAnalisis"].fillna("") + " " + copia["textoCabecera"]
    ).str.strip()

    return copia


DfDataset = enriquecerDataset(DfDataset)
DfResumenColumnas = resumirDataset(DfDataset)
DfResumenColumnas
```

Out[ ]:

	columna	tipo	nulos	unicos	min	ma
0	rutaArchivo	object	0	40	NaN	Na
1	nombreArchivo	object	0	40	NaN	Na
2	sha256	object	0	40	NaN	Na
3	tamanoBytes	int64	0	9	5.120000e+03	3.481600e+0
4	esPe	int64	0	1	1.000000e+00	1.000000e+0
5	machine	object	0	1	NaN	Na
6	compiladoEpoch	int64	0	15	1.195430e+09	1.319016e+0
7	numeroSecciones	int64	0	2	3.000000e+00	4.000000e+0
8	entryPoint	int64	0	11	2.763200e+04	3.422618e+0
9	imageBase	int64	0	2	4.194304e+06	2.684355e+0
10	subsystem	int64	0	1	2.000000e+00	2.000000e+0
11	dll	int64	0	2	0.000000e+00	1.000000e+0
12	aslr	int64	0	1	0.000000e+00	0.000000e+0
13	dep	int64	0	1	0.000000e+00	0.000000e+0
14	numeroImports	int64	0	6	7.000000e+00	8.500000e+0
15	numeroDlls	int64	0	6	4.000000e+00	9.000000e+0
16	numeroExports	int64	0	2	0.000000e+00	5.000000e+0
17	numeroRecursos	int64	0	2	0.000000e+00	1.000000e+0
18	numeroStrings	int64	0	34	8.300000e+01	5.696000e+0
19	entropiaArchivo	float64	0	40	5.650585e+00	7.894010e+0
20	entropiaPromedioSecciones	float64	0	40	3.379585e+00	4.884864e+0
21	empaquetadoHeuristico	int64	0	2	0.000000e+00	1.000000e+0
22	seccionesTexto	object	0	4	NaN	Na
23	dllsTexto	object	0	8	NaN	Na
24	funcionesTexto	object	0	9	NaN	Na
25	stringsTexto	object	0	38	NaN	Na
26	documentoAnalisis	object	0	38	NaN	Na
27	logTamanoBytes	float64	0	9	8.541105e+00	1.276042e+0
28	logNumeroStrings	float64	0	34	4.430817e+00	8.647695e+0
29	logNumeroImports	float64	0	6	2.079442e+00	4.454347e+0
30	logNumeroDlls	float64	0	6	1.609438e+00	2.302585e+0
31	logNumeroSecciones	float64	0	2	1.386294e+00	1.609438e+0
32	textoCabecera	object	0	2	NaN	Na

	columna	tipo	nulos	unicos	min	ma
33	documentoCompleto	object	0	38	NaN	Na

Preparacion de variables y preprocesamiento para clustering

In [ ]:
```
# prepara las variables para preprocesamietno
ColumnasNumericas = [
    "logTamanoBytes",
    "logNumeroStrings",
    "logNumeroImports",
    "logNumeroDlls",
    "logNumeroSecciones",
    "numeroExports",
    "numeroRecursos",
    "entryPoint",
    "imageBase",
    "entropiaArchivo",
    "entropiaPromedioSecciones",
    "dll",
    "aslr",
    "dep",
    "empaquetadoHeuristico",
]

ColumnasTexto = [
    "documentoCompleto",
]

XEntrada = DfDataset[ColumnasNumericas + ColumnasTexto].copy()

Preprocesador = ColumnTransformer(
    transformers=[
        ("numerico", StandardScaler(), ColumnasNumericas),
        (
            "texto",
            TfidfVectorizer(
                lowercase=True,
                token_pattern=r"(?u)\b[\w\.\-\:]{2,}\b",
                max_features=2500,
                ngram_range=(1, 2),
                min_df=1,
                max_df=0.95,
            ),
            "documentoCompleto",
        ),
    ],
    remainder="drop",
)

XMatriz = Preprocesador.fit_transform(XEntrada)
```

```
print("Forma matriz de features:", XMatriz.shape)
```

```
Forma matriz de features: (40, 2515)
```

Funciones para evaluar algoritmos de particionamiento

In [ ]:
```
# corre KMeans y KMedoids en un rango de k y devuelve metricas de codo y sil
def evaluarAlgoritmoParticion(matriz, listaK: list[int], nombreAlgoritmo: st
    filas = []
    modelos = {}

    for k in listaK:
        if nombreAlgoritmo.lower() == "kmeans":
            modelo = KMeans(
                n_clusters=k,
                random_state=semilla,
                n_init=20,
                max_iter=500,
            )
            etiquetas = modelo.fit_predict(matriz)
            errorCodo = float(modelo.inertia_)

        elif nombreAlgoritmo.lower() == "kmedoids":
            modelo = KMedoids(
                n_clusters=k,
                random_state=semilla,
                metric="euclidean",
                init="k-medoids++",
            )
            etiquetas = modelo.fit_predict(matriz)
            try:
                errorCodo = float(modelo.inertia_)
            except Exception:
                errorCodo = float("nan")
        else:
            raise ValueError("Algoritmo no soportado")

        puntajeSilhouette = float(silhouette_score(matriz, etiquetas))
        muestrasSilhouette = silhouette_samples(matriz, etiquetas)
        promedioPorCluster = []

        for clusterId in sorted(set(etiquetas)):
            promedioCluster = float(np.mean(muestrasSilhouette[etiquetas ==
            promedioPorCluster.append(promedioCluster)

        fila = {
            "algoritmo": nombreAlgoritmo,
            "k": int(k),
            "errorCodo": errorCodo,
            "silhouette": puntajeSilhouette,
            "silhouetteMinCluster": float(np.min(promedioPorCluster)),
            "silhouettePromedioClusters": float(np.mean(promedioPorCluster))
```

```
        }
        filas.append(fila)
        modelos[k] = {
            "modelo": modelo,
            "etiquetas": etiquetas,
            "silhouetteMuestras": muestrasSilhouette,
        }

    return pd.DataFrame(filas), modelos


# grafica la curva de codo y silhouette para un algoritmo
def graficarMetricasParticion(dataframeMetricas: pd.DataFrame, nombreAlgorit
    figura = plt.figure(figsize=(12, 5))

    plt.subplot(1, 2, 1)
    plt.plot(dataframeMetricas["k"], dataframeMetricas["errorCodo"], marker=
    plt.title(f"Codo {nombreAlgoritmo}")
    plt.xlabel("K")
    plt.ylabel("Error")

    plt.subplot(1, 2, 2)
    plt.plot(dataframeMetricas["k"], dataframeMetricas["silhouette"], marker
    plt.title(f"Silhouette {nombreAlgoritmo}")
    plt.xlabel("K")
    plt.ylabel("Silhouette")

    plt.tight_layout()
    plt.savefig(rutaSalida, dpi=200, bbox_inches="tight")
    plt.show()


# elige el mejor k segun silhouette maximo
def obtenerMejorKPorSilhouette(dataframeMetricas: pd.DataFrame) -> int:
    mejorFila = dataframeMetricas.sort_values(["silhouette", "k"], ascending
    return int(mejorFila["k"])
```

Evaluacion de KMeans con metodo del codo y Silhouette

In [ ]:

```
# evalua el mejor
DfMetricasKMeans, ModelosKMeans = evaluarAlgoritmoParticion(XMatriz, RangoK,
RutaKMeansGrafica = os.path.join(RutaGraficas, "metricasKMeans.png")
graficarMetricasParticion(DfMetricasKMeans, "KMeans", RutaKMeansGrafica)

print("Mejor K KMeans segun silhouette:", obtenerMejorKPorSilhouette(DfMetri
DfMetricasKMeans
```

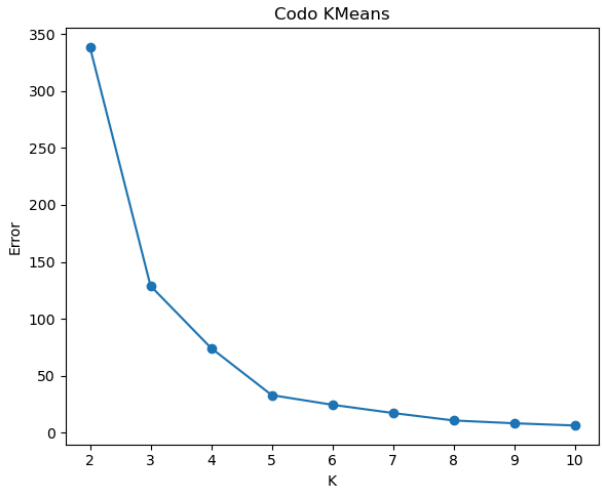

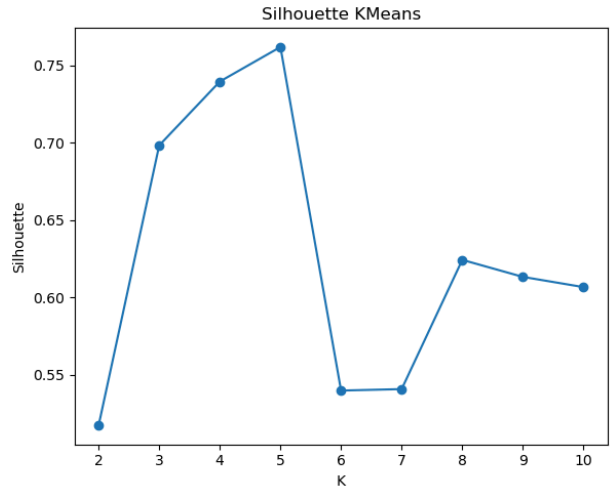


```
Mejor K KMeans segun silhouette: 5
```

Out[ ]:

	algoritmo	k	errorCodo	silhouette	silhouetteMinCluster	silhouetteProm
0	KMeans	2	338.553214	0.517337	0.439066	
1	KMeans	3	128.928998	0.698315	0.406160	
2	KMeans	4	74.327801	0.739556	0.673819	
3	KMeans	5	33.041774	0.761858	0.000000	
4	KMeans	6	24.575484	0.539905	0.000000	
5	KMeans	7	17.344782	0.540850	0.000000	
6	KMeans	8	10.804719	0.624331	0.000000	
7	KMeans	9	8.327073	0.613344	0.000000	
8	KMeans	10	6.394728	0.606737	0.000000	

Evaluacion de KMedoids con metodo del codo y Silhouette

In [ ]:

```
# evalua el mejor Kmedoids
DfMetricasKMedoids, ModelosKMedoids = evaluarAlgoritmoParticion(XMatriz, Rar
RutaKMedoidsGrafica = os.path.join(RutaGraficas, "metricasKMedoids.png")
graficarMetricasParticion(DfMetricasKMedoids, "KMedoids", RutaKMedoidsGrafic

print("Mejor K KMedoids segun silhouette:", obtenerMejorKPorSilhouette(DfMet
DfMetricasKMedoids
```

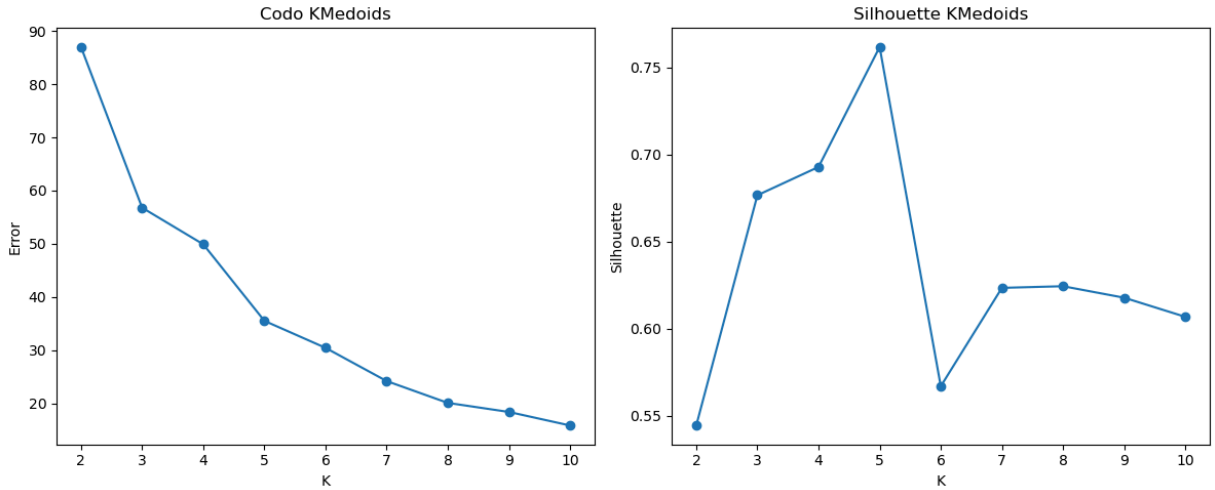


```
Mejor K KMedoids segun silhouette: 5
```

Out[ ]:

	algoritmo	k	errorCodo	silhouette	silhouetteMinCluster	silhouetteProme
0	KMedoids	2	86.982274	0.544264	0.498845	
1	KMedoids	3	56.773364	0.676642	0.445508	
2	KMedoids	4	49.901198	0.692890	0.000000	
3	KMedoids	5	35.511991	0.761858	0.000000	
4	KMedoids	6	30.437017	0.566828	0.000000	
5	KMedoids	7	24.192891	0.623386	0.000000	
6	KMedoids	8	20.092091	0.624331	0.000000	
7	KMedoids	9	18.389611	0.617724	0.000000	
8	KMedoids	10	15.844997	0.606737	0.000000	

Seleccion del mejor modelo y asignacion de clusters finales

In [ ]:

```
# se selecciona el mejor modelo
MejorKKMeans = obtenerMejorKPorSilhouette(DfMetricasKMeans)
MejorKKMedoids = obtenerMejorKPorSilhouette(DfMetricasKMedoids)
EtiquetasKMeans = ModelosKMeans[MejorKKMeans]["etiquetas"]
EtiquetasKMedoids = ModelosKMedoids[MejorKKMedoids]["etiquetas"]
DfDataset["clusterKMeans"] = EtiquetasKMeans
DfDataset["clusterKMedoids"] = EtiquetasKMedoids

SilhouetteKMeans = float(DfMetricasKMeans.loc[DfMetricasKMeans["k"] == Mejor
SilhouetteKMedoids = float(DfMetricasKMedoids.loc[DfMetricasKMedoids["k"] ==
AlgoritmoFinal = "KMeans" if SilhouetteKMeans >= SilhouetteKMedoids else "KM
ColumnaClusterFinal = "clusterKMeans" if AlgoritmoFinal == "KMeans" else "cl
MejorKFinal = MejorKKMeans if AlgoritmoFinal == "KMeans" else MejorKKMedoids
DfDataset["clusterFinal"] = DfDataset[ColumnaClusterFinal]
```

```
print("Algoritmo final:", AlgoritmoFinal)
print("Mejor K final:", MejorKFinal)
print("Silhouette final:", SilhouetteKMeans if AlgoritmoFinal == "KMeans" el

DfDataset[["nombreArchivo", "clusterKMeans", "clusterKMedoids", "clusterFina
```

```
Algoritmo final: KMeans
Mejor K final: 5
Silhouette final: 0.7618575204354998
```

Out[ ]:

	nombreArchivo	clusterKMeans	clusterKMedo
0	1F2EB7B090018D975E6D9B40868C94CA	1	
1	33DE5067A433A6EC5C328067DC18EC37	1	
2	65018CD542145A3792BA09985734C12A	1	
3	650A6FCA433EE243391E4B4C11F09438	1	
4	6FAA4740F99408D4D2DDDD0B09BBDEFD	1	
5	785003A405BC7A4EBCBB21DDB757BF3F	1	
6	8442AE37B91F279A9F06DE4C60B286A3	1	
7	99A39866A657A10949FCB6D634BB30D5	1	
8	A316D5AECA269CA865077E7FFF356E7D	1	
9	AAAz2E1B6940985A23E5639450F8391820655	2	
10	AL65_DB05DF0498B59B42A8E493CF3C10C578	2	
11	B07322743778B5868475DBE66EEDAC4F	1	
12	B98hX8E8622C393D7E832D39E620EAD5D3B49	3	
13	BVJ2D9FBF759F527AF373E34673DC3ACA462	1	
14	DS22_A670D13D4D014169C4080328B8FEB86	0	
15	EEE99EC8AA67B05407C01094184C33D2B5A44	1	
16	F6655E39465C2FF5B016980D918EA028	1	
17	F8437E44748D2C3FCF84019766F4E6DC	1	
18	FGJKJJ1_2BA0D0083976A5C1E3315413CDCFFCD2	1	
19	FGTR43_EF8E0FB20E7228C7492CCDC59D87C690	2	

Reduccion de dimensionalidad y visualizacion de clusters en 2D

In [ ]:

```
# se reduce la matriz a 2 dimensiones
def reducirADosDimensiones(matriz, semilla: int = 42) -> np.ndarray:
    if hasattr(matriz, "toarray"):
        matrizReducida = TruncatedSVD(n_components=min(50, max(2, matriz.sha
```

```
    else:
        matrizReducida = matriz

    coordenadas = PCA(n_components=2, random_state=semilla).fit_transform(ma
    return coordenadas


# grafica puntos 2D coloreados por cluster
def graficarClusters2D(coordenadas2D: np.ndarray, etiquetas: np.ndarray, tit
    plt.figure(figsize=(9, 7))
    dispersion = plt.scatter(coordenadas2D[:, 0], coordenadas2D[:, 1], c=eti
    plt.title(titulo)
    plt.xlabel("Componente 1")
    plt.ylabel("Componente 2")
    plt.grid(alpha=0.2)
    plt.savefig(rutaSalida, dpi=200, bbox_inches="tight")
    plt.show()


CoordenadasBase2D = reducirADosDimensiones(XMatriz, semilla=Semilla)
RutaClustersKMeans = os.path.join(RutaGraficas, "clusters2D_KMeans.png")
RutaClustersKMedoids = os.path.join(RutaGraficas, "clusters2D_KMedoids.png")
RutaClustersFinal = os.path.join(RutaGraficas, "clusters2D_Final.png")

graficarClusters2D(CoordenadasBase2D, DfDataset["clusterKMeans"].values, "Ag
graficarClusters2D(CoordenadasBase2D, DfDataset["clusterKMedoids"].values, "
graficarClusters2D(CoordenadasBase2D, DfDataset["clusterFinal"].values, "Agr
```

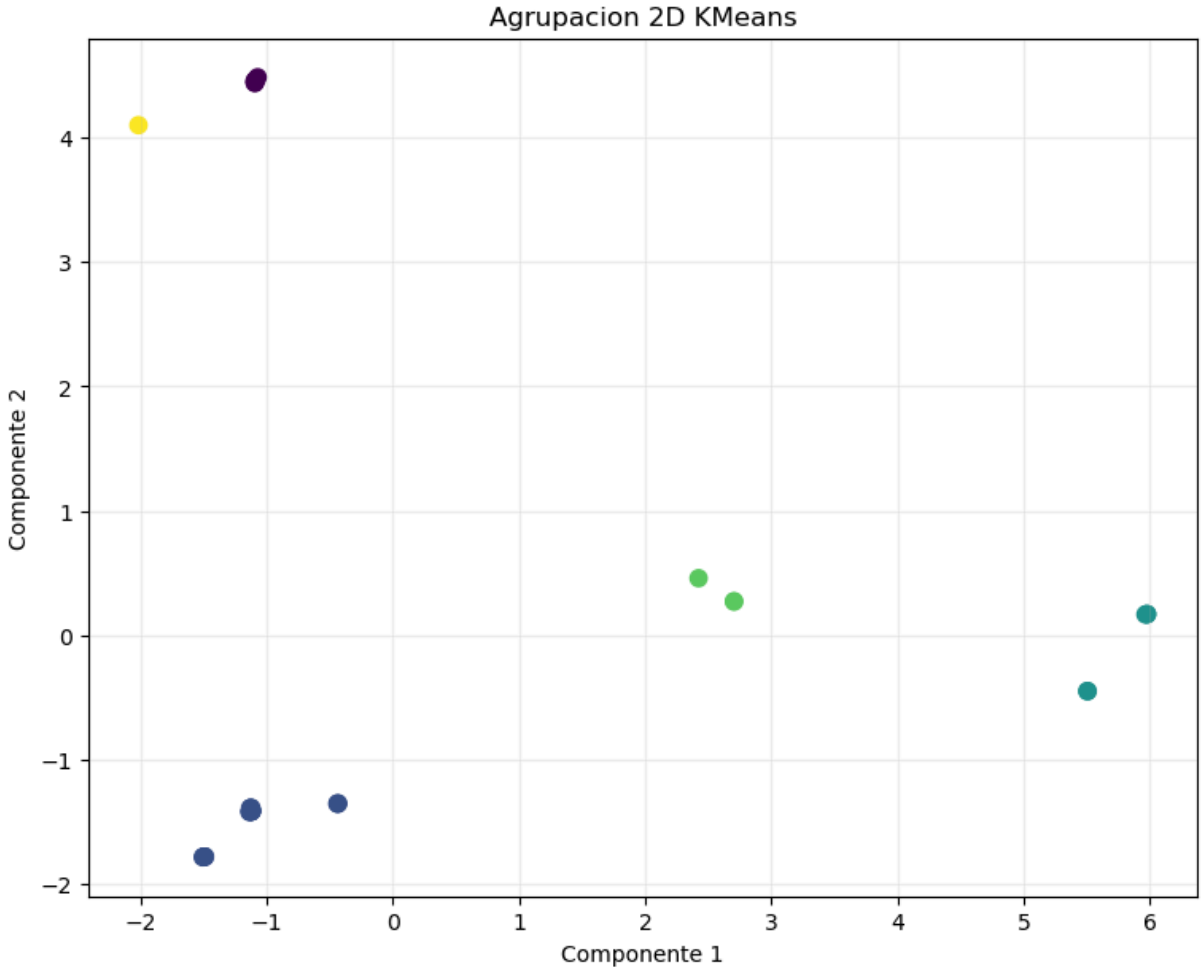
Agrupacion 2D KMeans
Componente 2
Componente 1
4
3
2
1
0
−1
−2
−2
−1
0
1
2
3
4
5
6

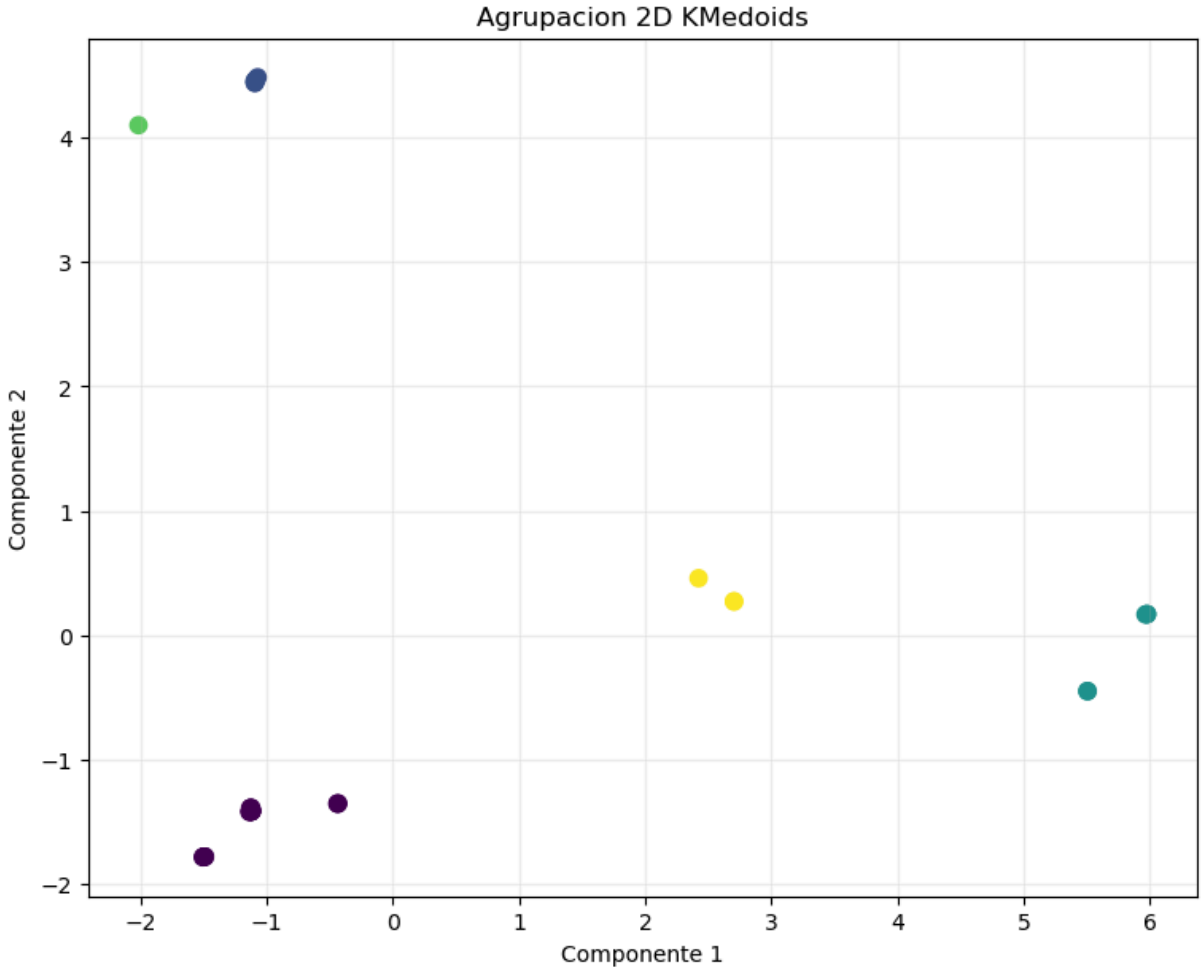
Agrupacion 2D KMedoids
Componente 2
Componente 1
4
3
2
1
0
−1
−2
−2
−1
0
1
2
3
4
5
6

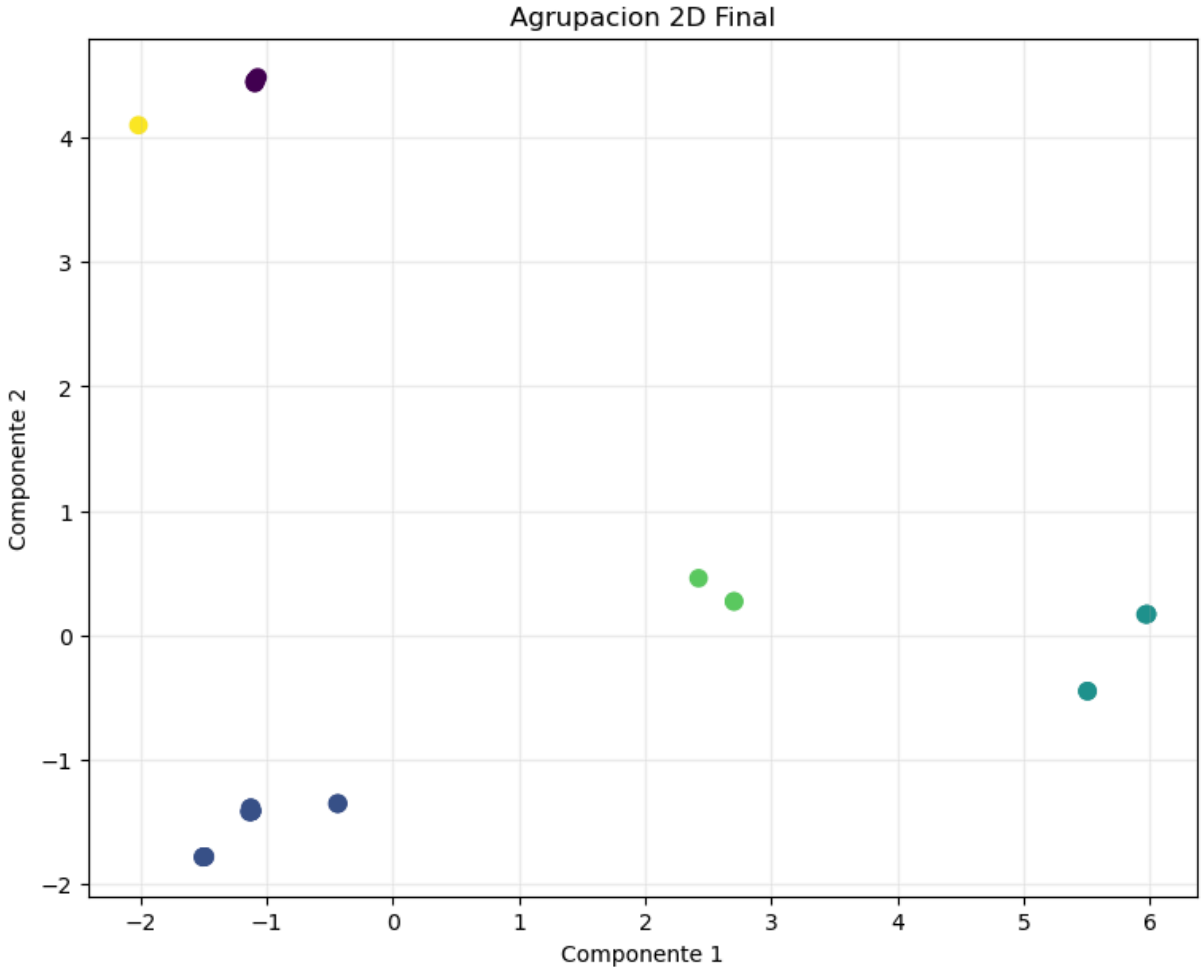

Funciones para generar embeddings de Gemini y reducirlos a 2D

In [ ]:
```
# se define la api key de Gemini se cambio por seguridad
%env GEMINI_API_KEY=xxxxx
```

```
env: GEMINI_API_KEY=xxxxx
```

In [ ]:
```
# aqui se generan los embeddings de Gemini por lotes
def generarEmbeddingsGemini(listaTextos: list[str], apiKey: str, modelo: str
    cliente = genai.Client(api_key=apiKey)
    listaEmbeddings = []

    for inicio in range(0, len(listaTextos), tamanoLote):
        fin = inicio + tamanoLote
        lote = listaTextos[inicio:fin]

        respuesta = cliente.models.embed_content(
            model=modelo,
            contents=lote,
            config=types.EmbedContentConfig(
                task_type="CLUSTERING",
                output_dimensionality=dimensionSalida,
```

```
            ),
        )

        for embedding in respuesta.embeddings:
            vector = np.array(embedding.values, dtype=np.float32)
            listaEmbeddings.append(vector)

        print(f"Lote procesado: {min(fin, len(listaTextos))}/{len(listaTexto
        time.sleep(1)

    return np.vstack(listaEmbeddings)


# Reduce embeddings a 2D para visualizarlos
def reducirEmbeddingsA2D(matrizEmbeddings: np.ndarray, semilla: int = 42) ->
    if len(matrizEmbeddings.shape) != 2:
        raise ValueError("La matriz de embeddings debe tener 2 dimensiones")
    numeroMuestras, numeroFeatures = matrizEmbeddings.shape
    if numeroMuestras < 2:
        raise ValueError("Se necesitan al menos 2 muestras para reducir a 2
    if numeroFeatures < 2:
        raise ValueError("Se necesitan al menos 2 features para reducir a 2
    maximoComponentesPermitidos = min(numeroMuestras - 1, numeroFeatures)
    if maximoComponentesPermitidos < 2:
        raise ValueError("No hay suficientes dimensiones para aplicar PCA a
    if numeroFeatures > 50:
        componentesIntermedios = min(50, maximoComponentesPermitidos)
        if componentesIntermedios >= 2:
            matrizBase = PCA(
                n_components=componentesIntermedios,
                random_state=semilla
            ).fit_transform(matrizEmbeddings)
        else:
            matrizBase = matrizEmbeddings
    else:
        matrizBase = matrizEmbeddings
    numeroMuestrasBase, numeroFeaturesBase = matrizBase.shape
    componentesFinales = min(2, numeroMuestrasBase, numeroFeaturesBase)
    if componentesFinales < 2:
        raise ValueError("No fue posible reducir los embeddings a 2 dimensio
    coordenadas = PCA(
        n_components=2,
        random_state=semilla
    ).fit_transform(matrizBase)

    return coordenadas
```

Generacion de embeddings de Gemini

In [ ]:

```
# se llama la api keey y se generan los embeddings y se guardan para preveni
# con ayuda de gpt para establecerlo funcional
ApiKeyGemini = os.getenv("GEMINI_API_KEY", "").strip()

RutaEmbeddingsNpy = os.path.join(RutaTablas, "embeddingsGemini.npy")
```

```
RutaEmbeddingsCheckpointNpy = os.path.join(RutaTablas, "embeddingsGemini_che
RutaEmbeddingsEstadoJson = os.path.join(RutaTablas, "embeddingsGemini_estado
RutaGemini2D = os.path.join(RutaGraficas, "embeddingsGemini2D.png")

# se definen los tamanio
TamanoLoteGemini = 5
DimensionSalidaGemini = 256
EsperaEntreLotesSegundos = 5
EsperaPorQuotaSegundos = 130
MaxReintentosPorLote = 100

if not ApiKeyGemini:
    print("No se encontro GEMINI_API_KEY")
    print("Antes de correr esta celda exporta tu llave")
    print("Ejemplo en notebook:")
    print('%env GEMINI_API_KEY=TU_API_KEY')
else:
    ListaDocumentosGemini = DfDataset["documentoCompleto"].fillna("").astype
    TotalDocumentos = len(ListaDocumentosGemini)
    cliente = genai.Client(api_key=ApiKeyGemini)
    EmbeddingsAcumulados = []
    IndiceInicio = 0

    if os.path.exists(RutaEmbeddingsCheckpointNpy):
        try:
            EmbeddingsAcumulados = np.load(RutaEmbeddingsCheckpointNpy).toli
            IndiceInicio = len(EmbeddingsAcumulados)
            print(f"Checkpoint encontrado. Se reanuda desde {IndiceInicio}/{
        except Exception:
            EmbeddingsAcumulados = []
            IndiceInicio = 0
            print("No se pudo leer el checkpoint anterior. Se reinicia el pr

    if os.path.exists(RutaEmbeddingsEstadoJson):
        try:
            with open(RutaEmbeddingsEstadoJson, "r", encoding="utf-8") as ar
                EstadoGuardado = json.load(archivoEstado)
            IndiceEstado = int(EstadoGuardado.get("indiceProcesado", IndiceI
            if IndiceEstado > IndiceInicio:
                IndiceInicio = IndiceEstado
            print(f"Estado detectado. Ultimo indice procesado: {IndiceInicio
        except Exception:
            print("No se pudo leer el estado json. Se usa el checkpoint disp

    while IndiceInicio < TotalDocumentos:
        IndiceFin = min(IndiceInicio + TamanoLoteGemini, TotalDocumentos)
        LoteActual = ListaDocumentosGemini[IndiceInicio:IndiceFin]
        Reintentos = 0
        LoteProcesado = False

        while not LoteProcesado and Reintentos < MaxReintentosPorLote:
            try:
                respuesta = cliente.models.embed_content(
                    model=ModeloGeminiEmbeddings,
                    contents=LoteActual,
                    config=types.EmbedContentConfig(
```

```
                        task_type="CLUSTERING",
                        output_dimensionality=DimensionSalidaGemini,
                    ),
                )

                for embedding in respuesta.embeddings:
                    vector = np.array(embedding.values, dtype=np.float32)
                    EmbeddingsAcumulados.append(vector)

                MatrizParcial = np.vstack(EmbeddingsAcumulados)
                np.save(RutaEmbeddingsCheckpointNpy, MatrizParcial)
                with open(RutaEmbeddingsEstadoJson, "w", encoding="utf-8") a
                    json.dump(
                        {
                            "indiceProcesado": len(EmbeddingsAcumulados),
                            "totalDocumentos": TotalDocumentos,
                            "tamanoLote": TamanoLoteGemini,
                            "dimensionSalida": DimensionSalidaGemini,
                        },
                        archivoEstado,
                        ensure_ascii=False,
                        indent=2,
                    )

                IndiceInicio = len(EmbeddingsAcumulados)
                LoteProcesado = True
                print(f"Lote procesado: {IndiceInicio}/{TotalDocumentos}")

                if IndiceInicio < TotalDocumentos:
                    time.sleep(EsperaEntreLotesSegundos)

            except Exception as error:
                MensajeError = str(error)
                Reintentos += 1
                if "429" in MensajeError or "RESOURCE_EXHAUSTED" in MensajeE
                    print(f"Quota alcanzada en lote {IndiceInicio}:{IndiceFi
                    print(f"Esperando {EsperaPorQuotaSegundos} segundos para
                    time.sleep(EsperaPorQuotaSegundos)
                else:
                    print(f"Error inesperado en lote {IndiceInicio}:{IndiceF
                    print(MensajeError)
                    raise

        if not LoteProcesado:
            raise RuntimeError("No se pudo procesar un lote despues de multi

    MatrizEmbeddingsGemini = np.vstack(EmbeddingsAcumulados).astype(np.float
    np.save(RutaEmbeddingsNpy, MatrizEmbeddingsGemini)
    CoordenadasGemini2D = reducirEmbeddingsA2D(MatrizEmbeddingsGemini, semil

    plt.figure(figsize=(9, 7))
    plt.scatter(CoordenadasGemini2D[:, 0], CoordenadasGemini2D[:, 1], c=DfDa
    plt.title("Embeddings Gemini en 2D")
    plt.xlabel("Componente 1")
    plt.ylabel("Componente 2")
    plt.grid(alpha=0.2)
```

```
    plt.savefig(RutaGemini2D, dpi=200, bbox_inches="tight")
    plt.show()

    print("Embeddings guardados en:", RutaEmbeddingsNpy)
    print("Checkpoint guardado en:", RutaEmbeddingsCheckpointNpy)
    print("Estado guardado en:", RutaEmbeddingsEstadoJson)
```

```
Checkpoint encontrado. Se reanuda desde 40/40
Estado detectado. Ultimo indice procesado: 40/40
```

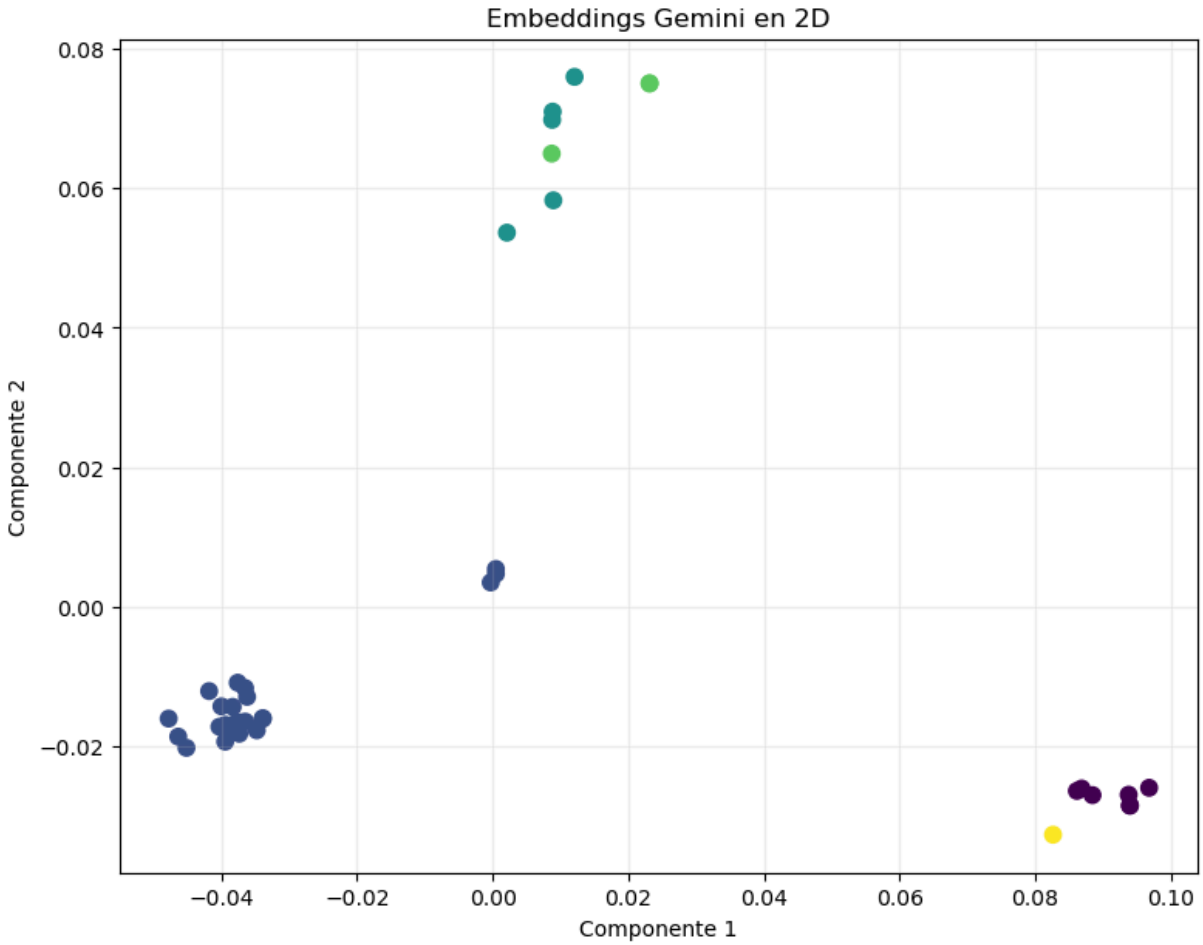


```
Embeddings guardados en: ./salidasLab3/tablas/embeddingsGemini.npy
Checkpoint guardado en: ./salidasLab3/tablas/embeddingsGemini_checkpoint.npy
Estado guardado en: ./salidasLab3/tablas/embeddingsGemini_estado.json
```

Funciones para calcular similitud de Jaccard entre muestras

In [ ]:
```
# se contruyen mapas archivo a conjunto de strings y funciones
def construirMapasFeatures(dataframe: pd.DataFrame) -> tuple[dict[str, set[s
    mapaStrings = {}
    mapaFunciones = {}

    for _, fila in dataframe.iterrows():
        rutaArchivo = fila["rutaArchivo"]
        stringsLista = str(fila["stringsTexto"]).split() if pd.notna(fila["s
        funcionesLista = str(fila["funcionesTexto"]).split() if pd.notna(fil
```

```
        mapaStrings[rutaArchivo] = listaAConjunto(stringsLista)
        mapaFunciones[rutaArchivo] = listaAConjunto(funcionesLista)

    return mapaStrings, mapaFunciones


# se calcula similitud por pares para todos los archivos
def calcularSimilitudesPares(mapaFeatures: dict[str, set[str]]) -> pd.DataFr
    archivos = sorted(mapaFeatures.keys())
    filas = []
    for archivoA, archivoB in combinations(archivos, 2):
        similitud = jaccardConjuntos(mapaFeatures[archivoA], mapaFeatures[ar
        filas.append({
            "archivoA": archivoA,
            "archivoB": archivoB,
            "similitud": float(similitud),
        })
    return pd.DataFrame(filas)


# Resumelel resumene cuantas conexiones existen por umbral
def resumirPorUmbrales(dataframeSimilitud: pd.DataFrame, listaUmbrales: list
    filas = []
    if dataframeSimilitud.empty:
        return pd.DataFrame()
    promedio = float(dataframeSimilitud["similitud"].mean())
    mediana = float(dataframeSimilitud["similitud"].median())
    paresTotales = int(len(dataframeSimilitud))
    for umbral in listaUmbrales:
        conectados = int((dataframeSimilitud["similitud"] >= umbral).sum())
        porcentaje = float((conectados / paresTotales) * 100.0) if paresTota

        filas.append({
            "umbral": float(umbral),
            "paresTotales": paresTotales,
            "paresConectados": conectados,
            "porcentajeConectado": porcentaje,
            "promedioSimilitud": promedio,
            "medianaSimilitud": mediana,
        })

    return pd.DataFrame(filas)
```

Calculo y resumen de similitud para strings y funciones

In [ ]:
```
MapaStrings, MapaFunciones = construirMapasFeatures(DfDataset)
DfSimStrings = calcularSimilitudesPares(MapaStrings)
DfSimFunciones = calcularSimilitudesPares(MapaFunciones)
DfResumenStrings = resumirPorUmbrales(DfSimStrings, ListaUmbrales)
DfResumenFunciones = resumirPorUmbrales(DfSimFunciones, ListaUmbrales)
RutaSimStrings = os.path.join(RutaTablas, "similitudStrings.csv")
RutaSimFunciones = os.path.join(RutaTablas, "similitudFunciones.csv")
```

```
RutaResumenStrings = os.path.join(RutaTablas, "resumenUmbralesStrings.csv")
RutaResumenFunciones = os.path.join(RutaTablas, "resumenUmbralesFunciones.cs

DfSimStrings.to_csv(RutaSimStrings, index=False, encoding="utf-8")
DfSimFunciones.to_csv(RutaSimFunciones, index=False, encoding="utf-8")
DfResumenStrings.to_csv(RutaResumenStrings, index=False, encoding="utf-8")
DfResumenFunciones.to_csv(RutaResumenFunciones, index=False, encoding="utf-8

print("Resumen strings")
display(DfResumenStrings)

print("Resumen funciones")
display(DfResumenFunciones)
```

Resumen strings

	umbral	paresTotales	paresConectados	porcentajeConectado	promedioSimi
0	0.60	780	110	14.102564	0.18
1	0.80	780	26	3.333333	0.18
2	0.95	780	9	1.153846	0.18

Resumen funciones

	umbral	paresTotales	paresConectados	porcentajeConectado	promedioSimi
0	0.60	780	256	32.820513	0.38
1	0.80	780	149	19.102564	0.38
2	0.95	780	149	19.102564	0.38

Funciones para generar grafos de similitud

In [ ]:
```
# se dibujan un grafo de similitud y lo guarda como png
def generarGrafoSimilitud(dataframeCluster: pd.DataFrame, mapaFeatures: dict
    grafo = nx.Graph()
    archivos = dataframeCluster["rutaArchivo"].tolist()
    nombres = dict(zip(dataframeCluster["rutaArchivo"], dataframeCluster["nc
    for rutaArchivo in archivos:
        grafo.add_node(rutaArchivo, label=nombres[rutaArchivo])
    for archivoA, archivoB in combinations(archivos, 2):
        similitud = jaccardConjuntos(mapaFeatures.get(archivoA, set()), mapa
        if similitud >= umbral:
            grafo.add_edge(archivoA, archivoB, weight=similitud)
    plt.figure(figsize=(12, 9))
    posiciones = nx.spring_layout(grafo, seed=Semilla, k=0.8)
    nx.draw_networkx_nodes(grafo, posiciones, node_size=900)
    nx.draw_networkx_labels(
        grafo,
        posiciones,
```

```
        labels={nodo: grafo.nodes[nodo]["label"][:18] for nodo in grafo.node
        font_size=8,
    )

    if grafo.number_of_edges() > 0:
        pesos = [grafo[u][v]["weight"] * 3 for u, v in grafo.edges()]
        nx.draw_networkx_edges(grafo, posiciones, width=pesos, alpha=0.7)
    plt.title(titulo)
    plt.axis("off")
    plt.savefig(rutaSalida, dpi=220, bbox_inches="tight")
    plt.show()


# se generan grafos y por familia para cada umbral y tipo de feature
def generarTodosLosGrafos(dataframe: pd.DataFrame, mapaFeatures: dict[str, s
    for umbral in listaUmbrales:
        rutaCompleta = os.path.join(carpetaSalida, f"grafoCompleto_{nombreFe
        generarGrafoSimilitud(
            dataframeCluster=dataframe,
            mapaFeatures=mapaFeatures,
            umbral=umbral,
            titulo=f"Grafo completo {nombreFeature} umbral {umbral}",
            rutaSalida=rutaCompleta,
        )

        for clusterId in sorted(dataframe["clusterFinal"].unique()):
            dataframeCluster = dataframe[dataframe["clusterFinal"] == cluste
            rutaFamilia = os.path.join(carpetaSalida, f"grafoFamilia_{nombre
            generarGrafoSimilitud(
                dataframeCluster=dataframeCluster,
                mapaFeatures=mapaFeatures,
                umbral=umbral,
                titulo=f"Familia {clusterId} {nombreFeature} umbral {umbral}
                rutaSalida=rutaFamilia,
            )
```

Generacion de grafos completos y por familia

In [ ]:
```
# se imprimen ya los grafos a generar y se ven las utas guardadas
generarTodosLosGrafos(DfDataset, MapaStrings, "strings", ListaUmbrales, Ruta
generarTodosLosGrafos(DfDataset, MapaFunciones, "funciones", ListaUmbrales,

print("Grafos generados en:", RutaGrafos)
```

Grafo completo strings umbral 0.6

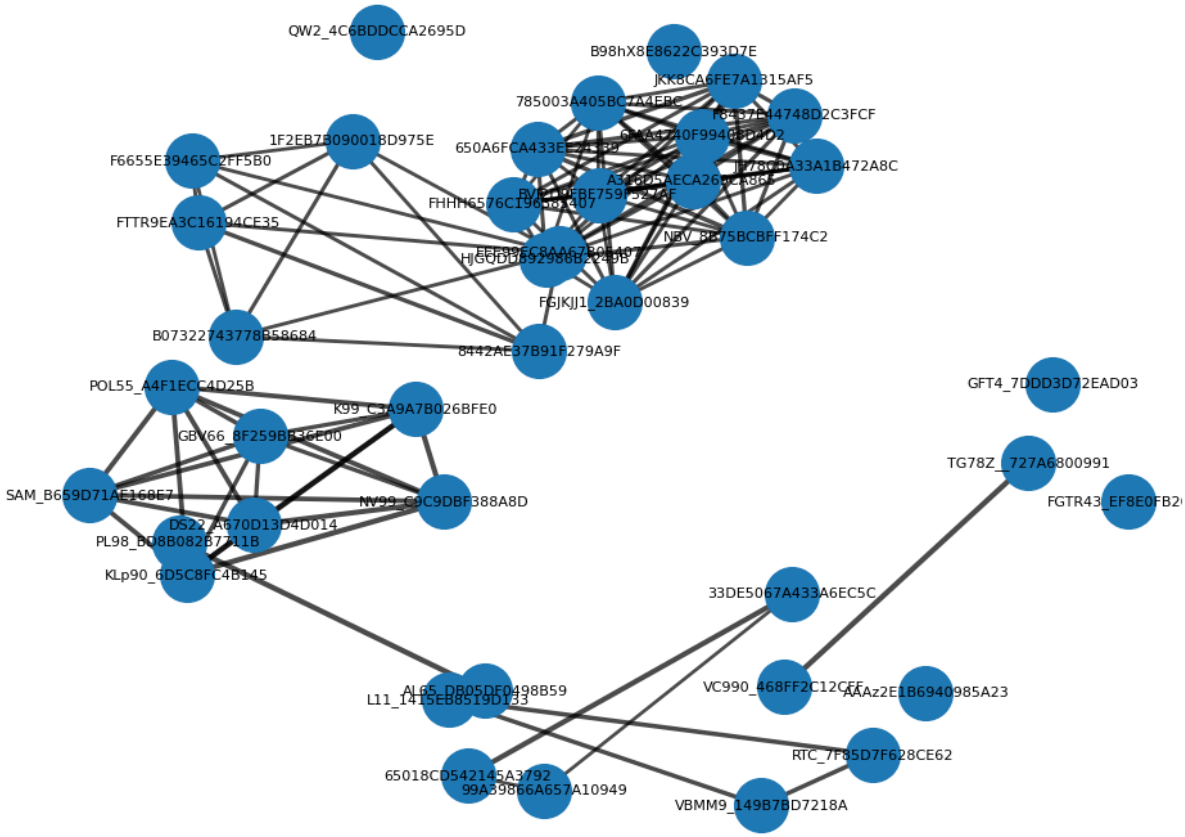

Familia 0 strings umbral 0.6

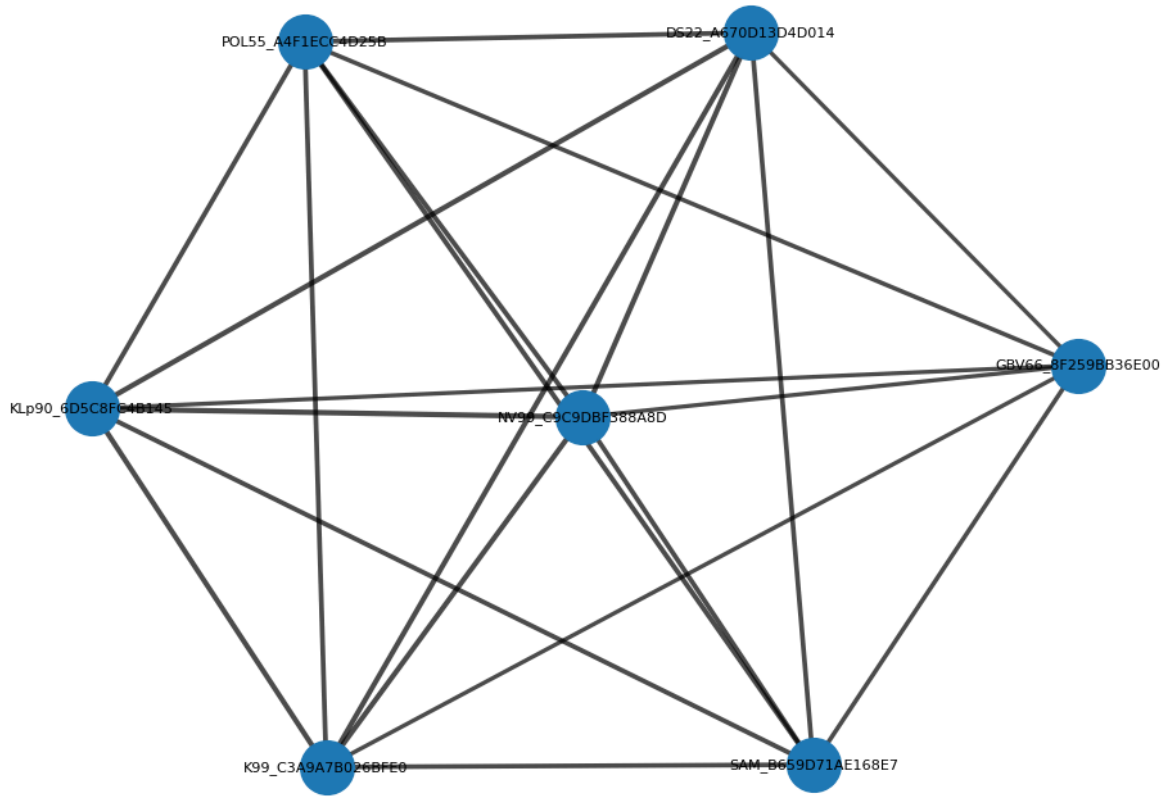

Familia 1 strings umbral 0.6

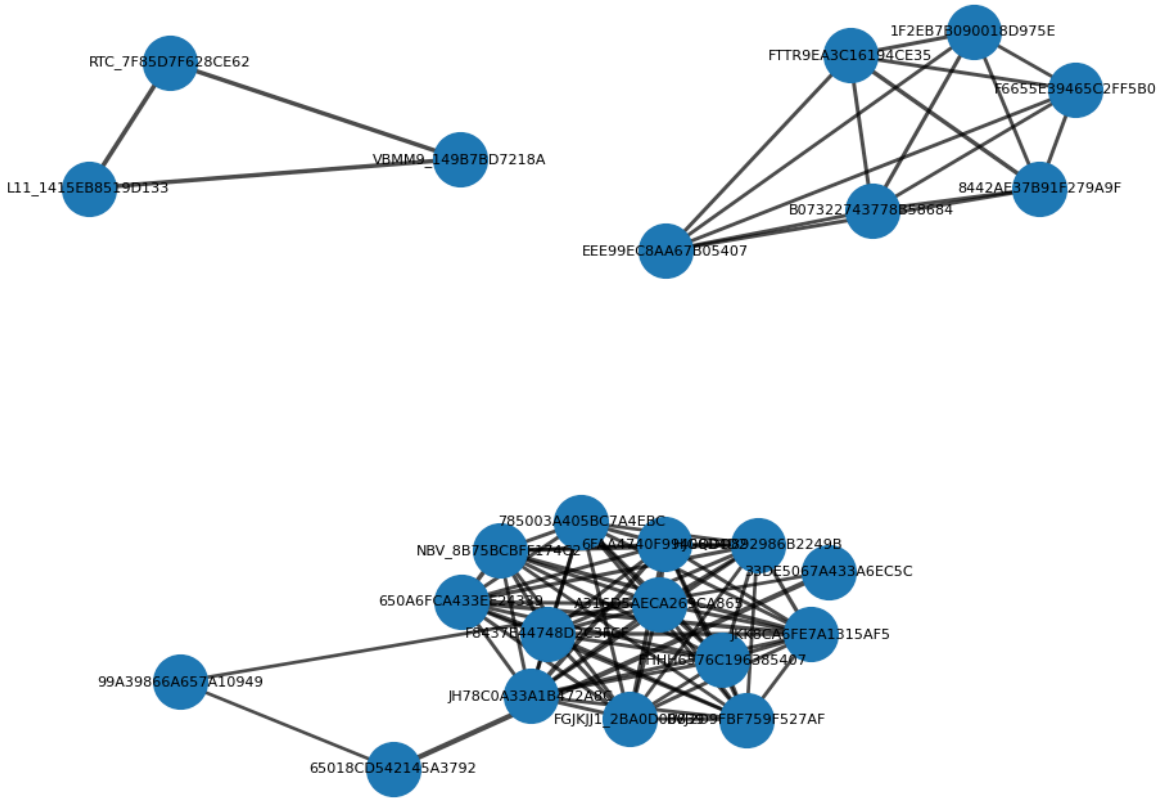

Familia 2 strings umbral 0.6

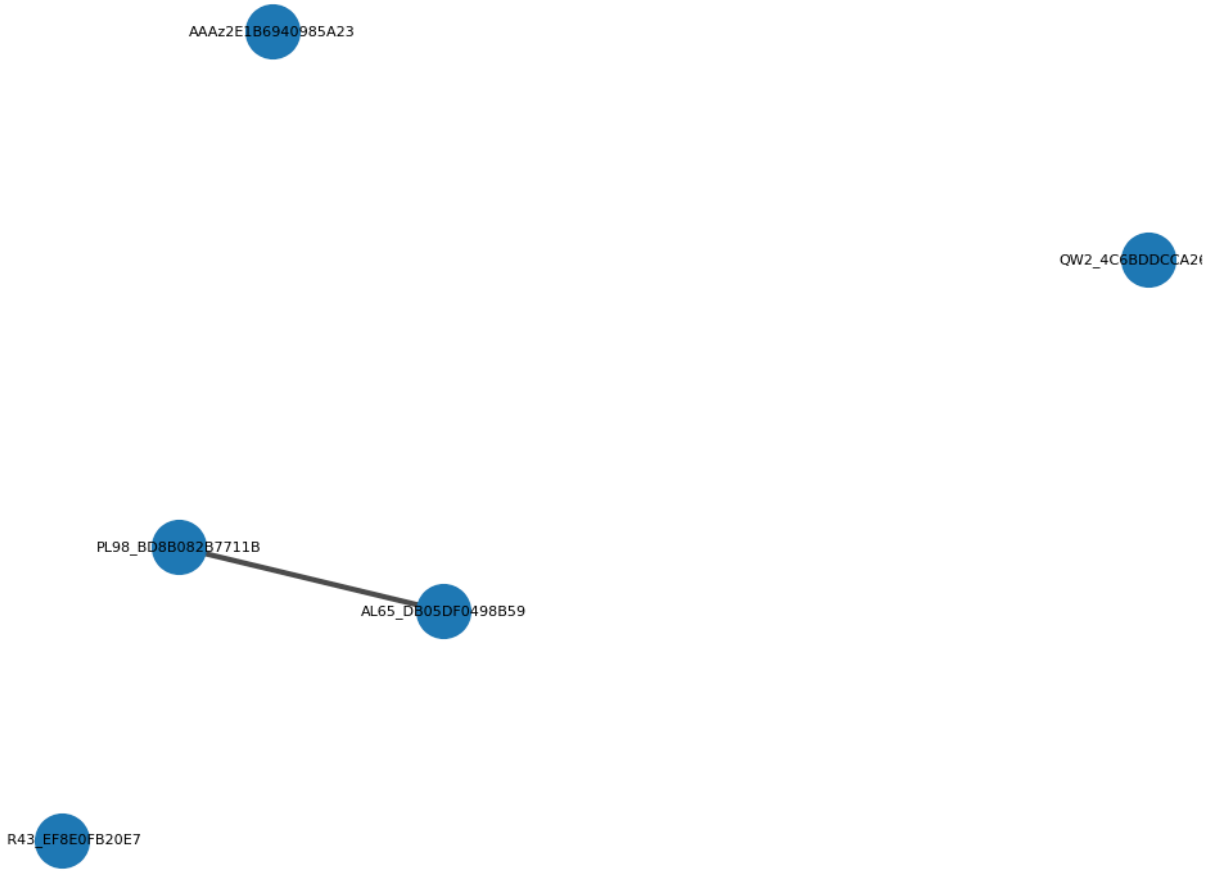

Familia 3 strings umbral 0.6

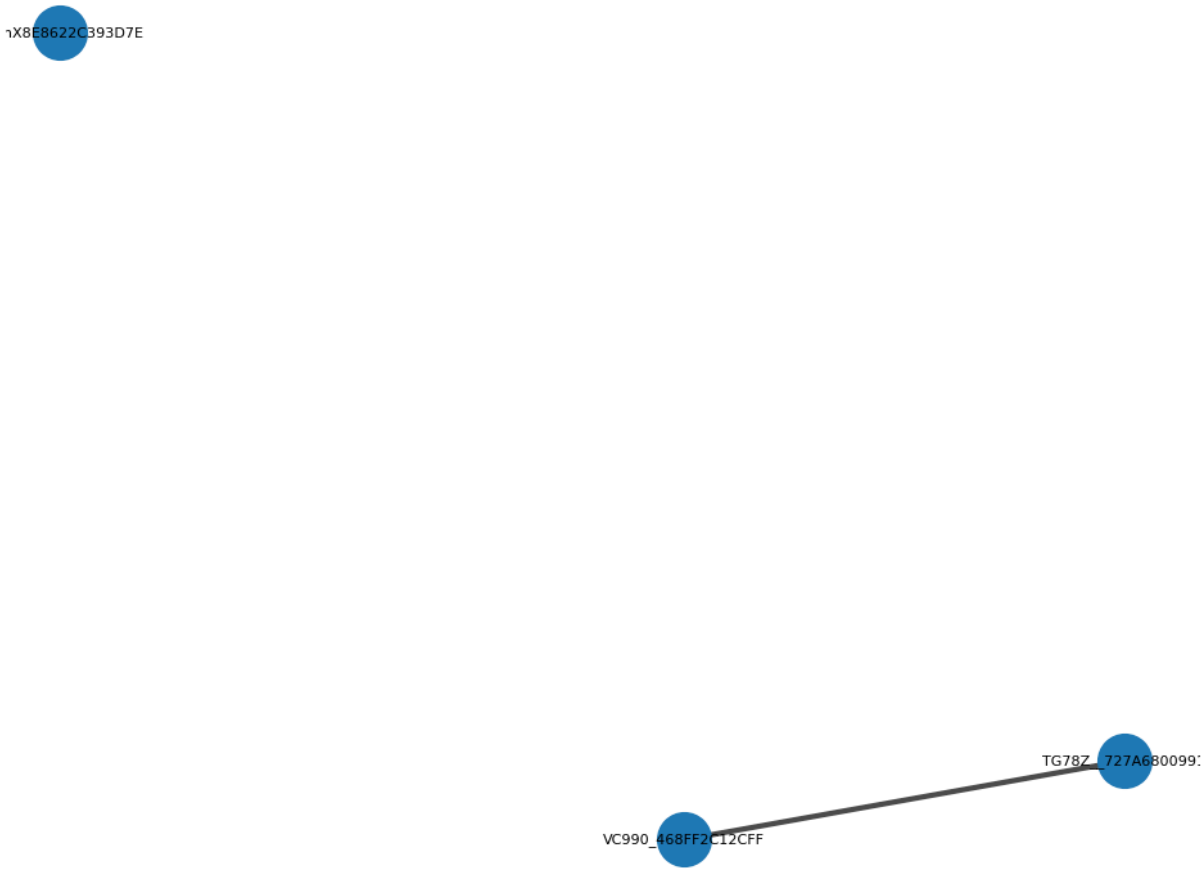

Familia 4 strings umbral 0.6

Grafo completo strings umbral 0.8

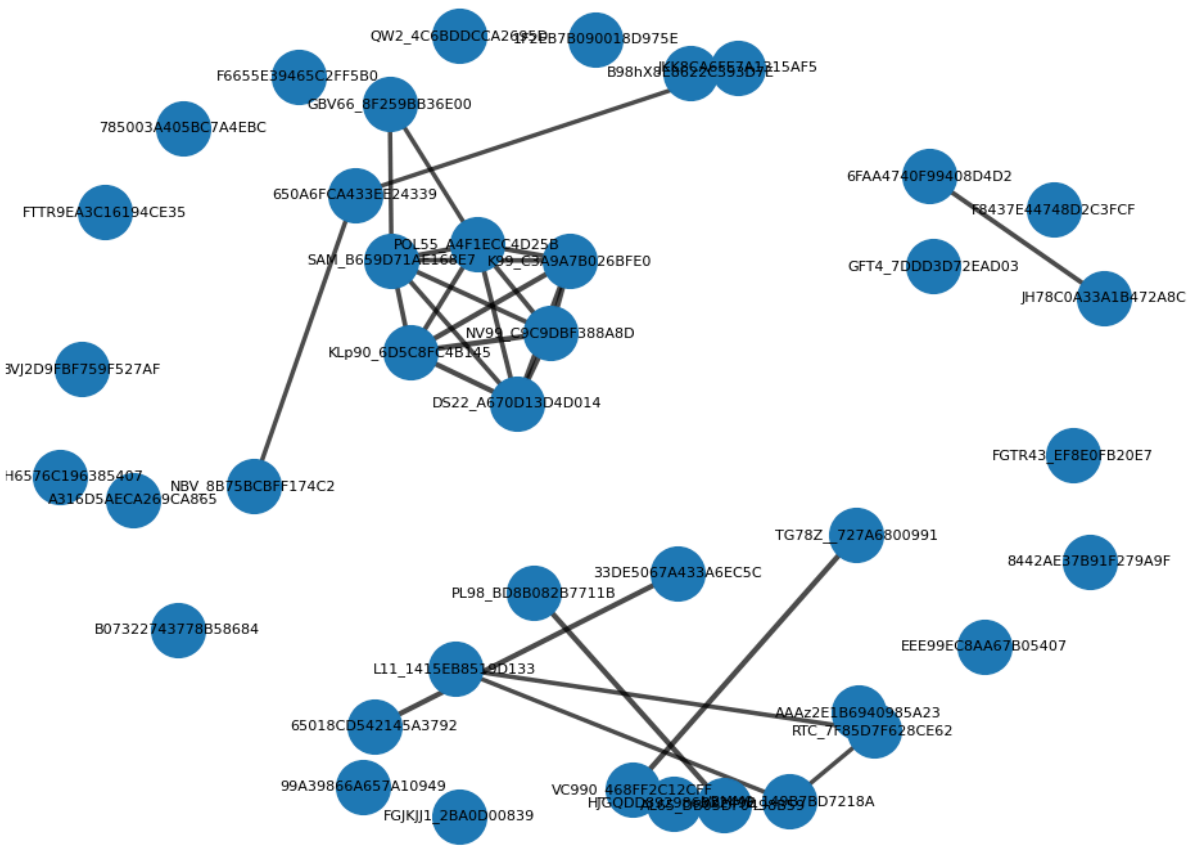

Familia 0 strings umbral 0.8

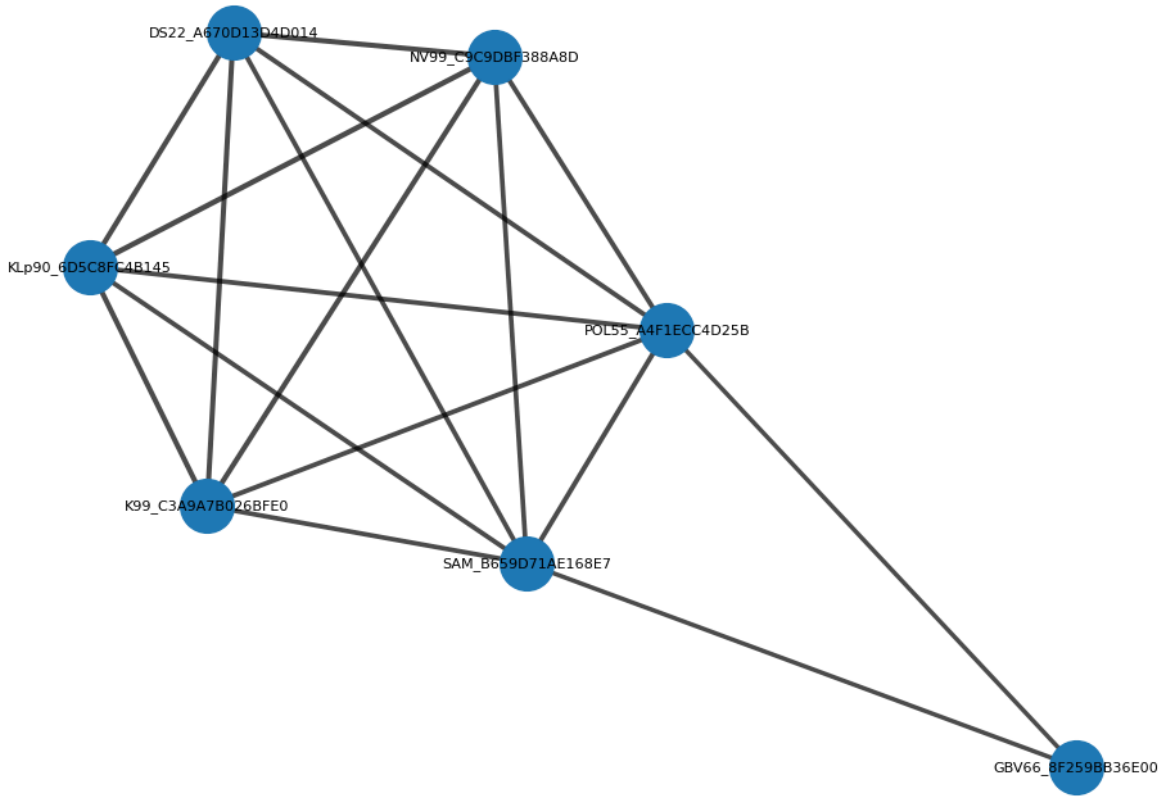

Familia 1 strings umbral 0.8

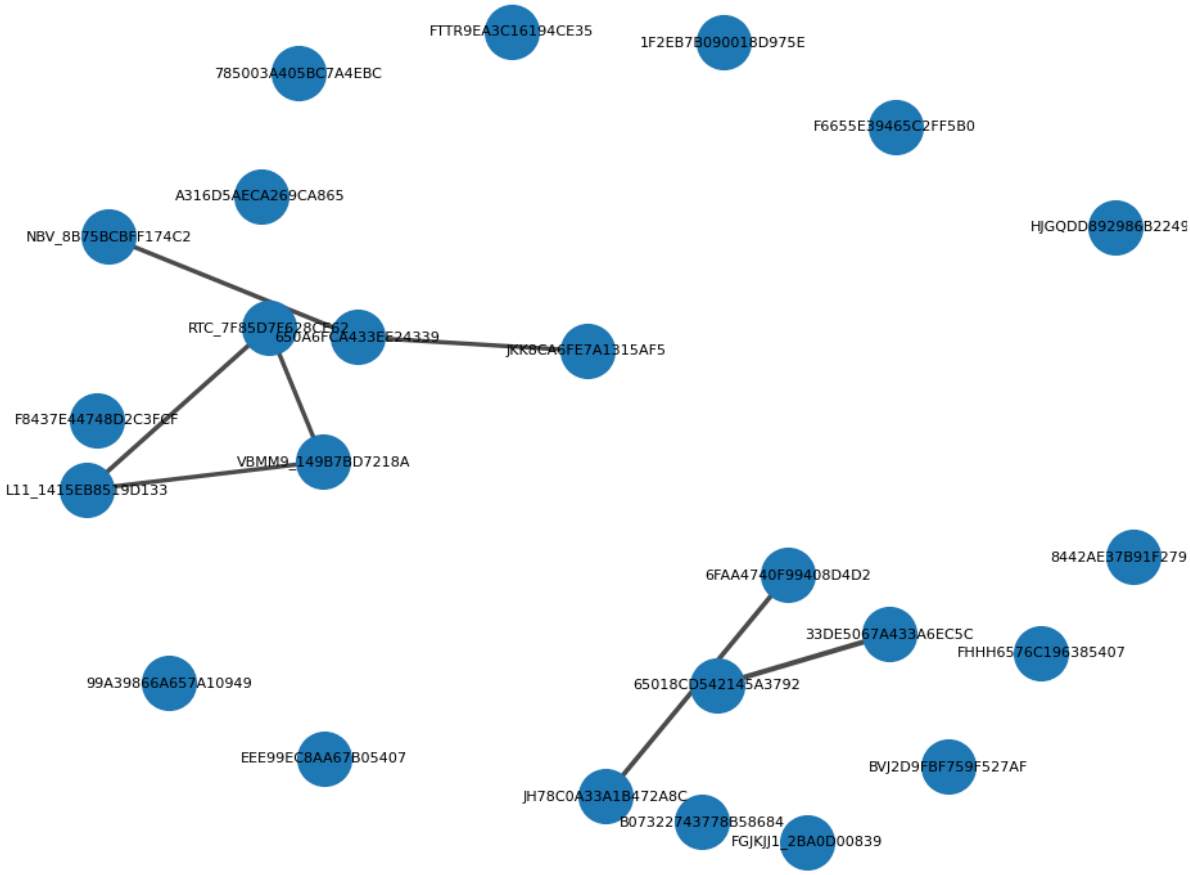

Familia 2 strings umbral 0.8

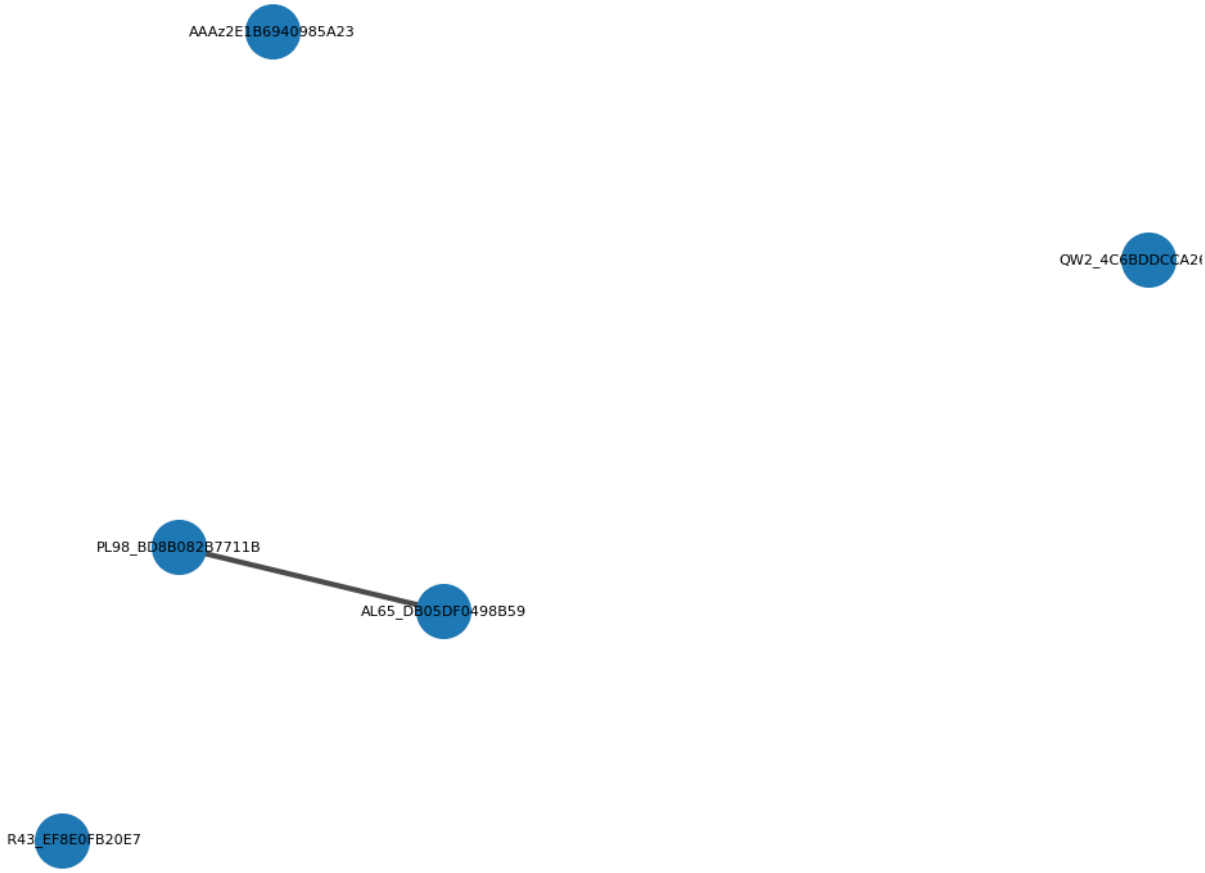

Familia 3 strings umbral 0.8

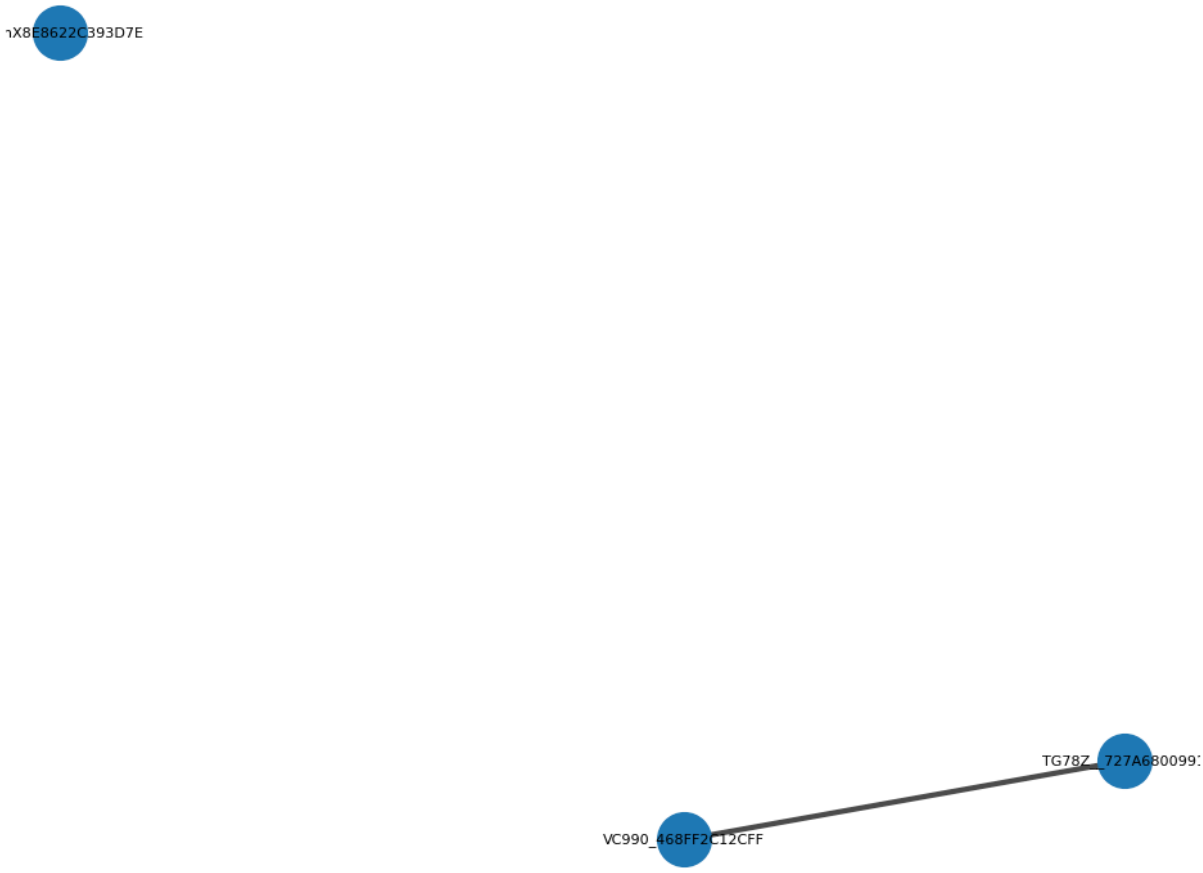

Familia 4 strings umbral 0.8

Grafo completo strings umbral 0.95

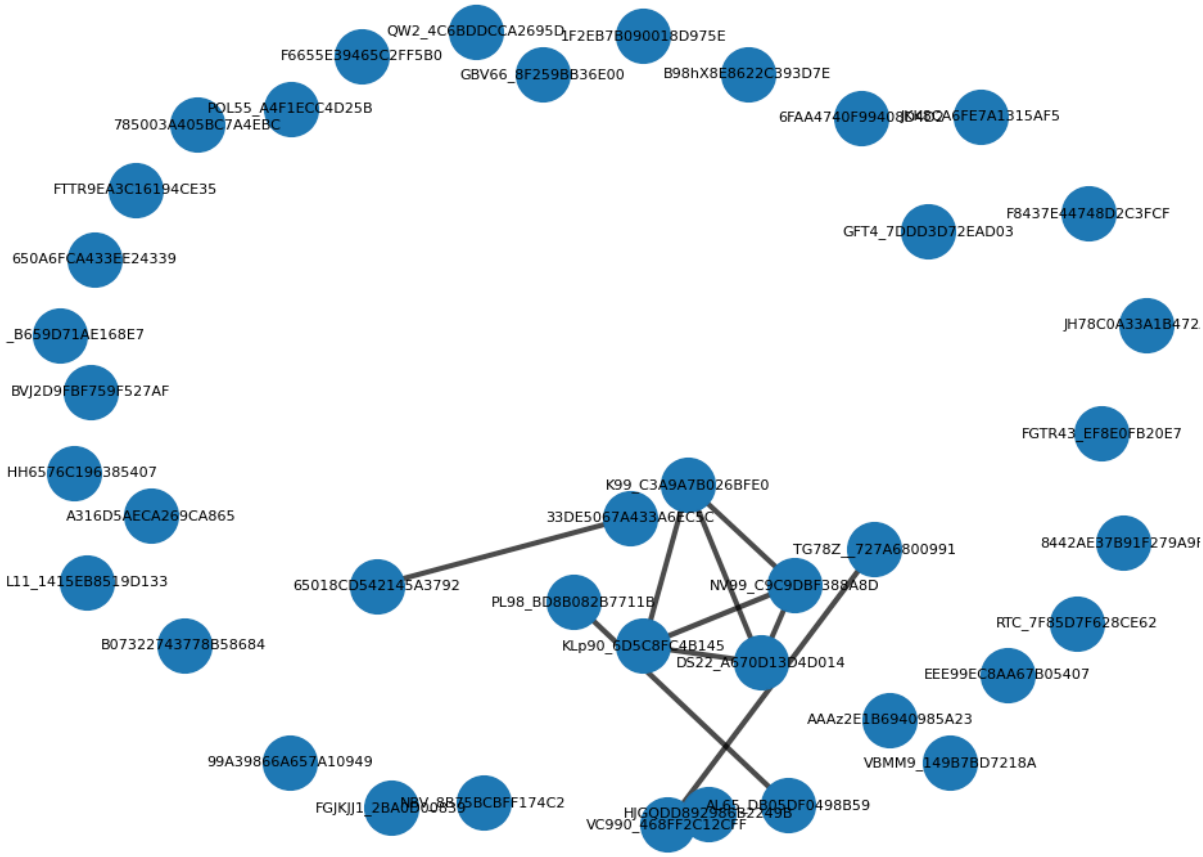

Familia 0 strings umbral 0.95

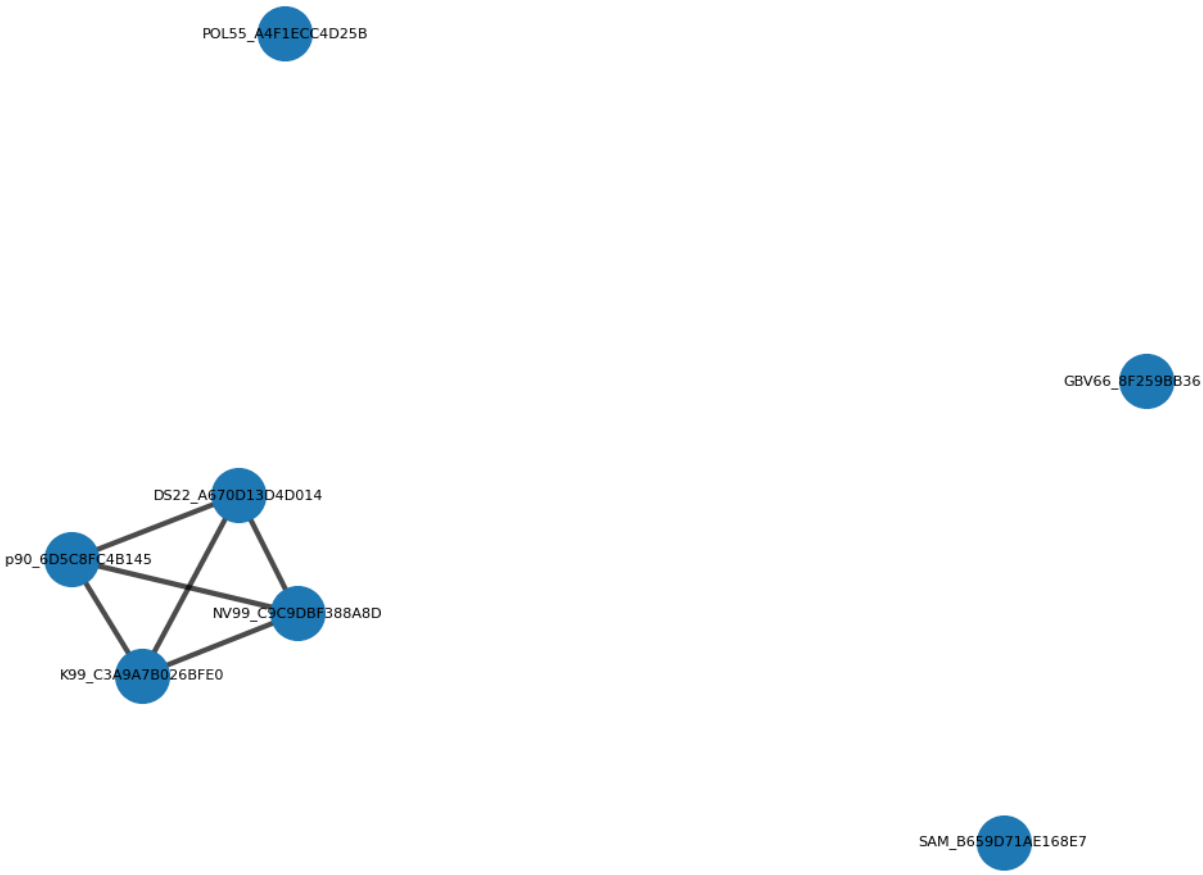

Familia 1 strings umbral 0.95

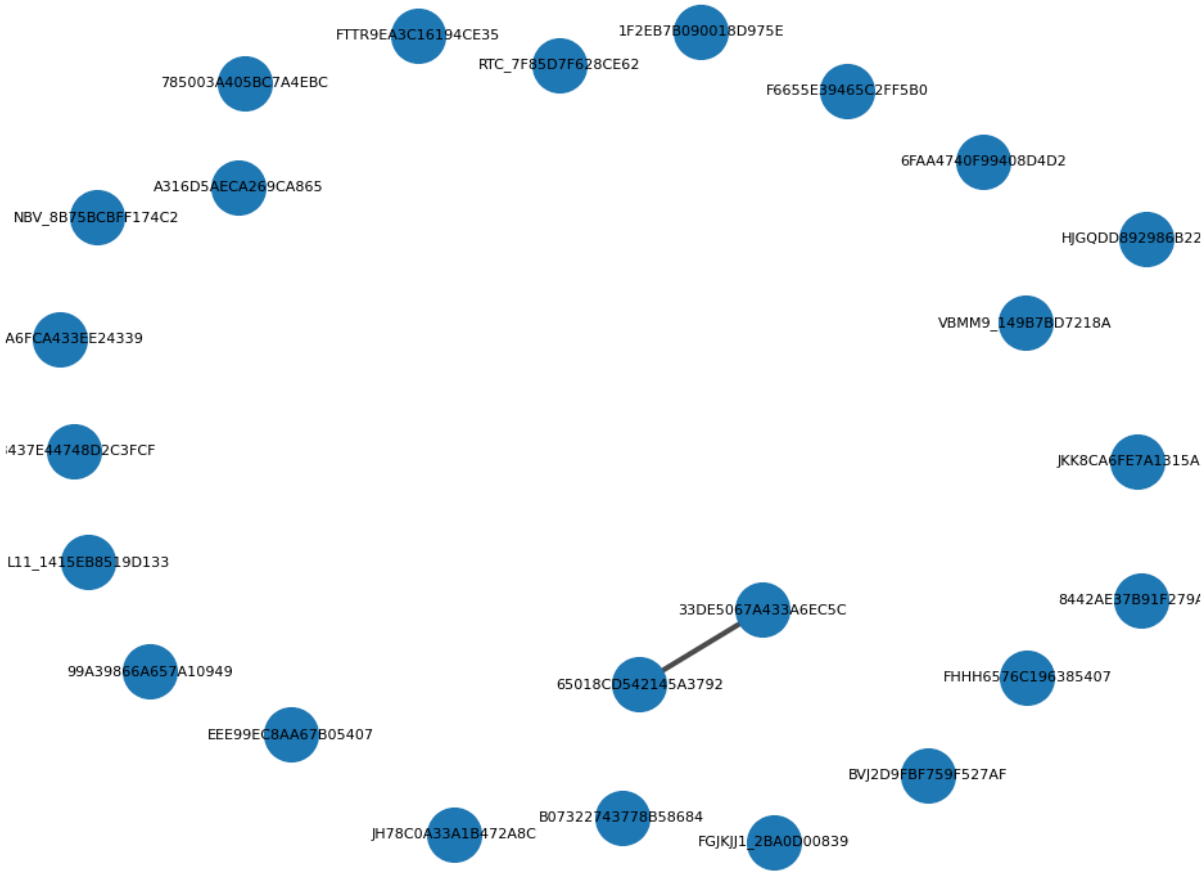

Familia 2 strings umbral 0.95

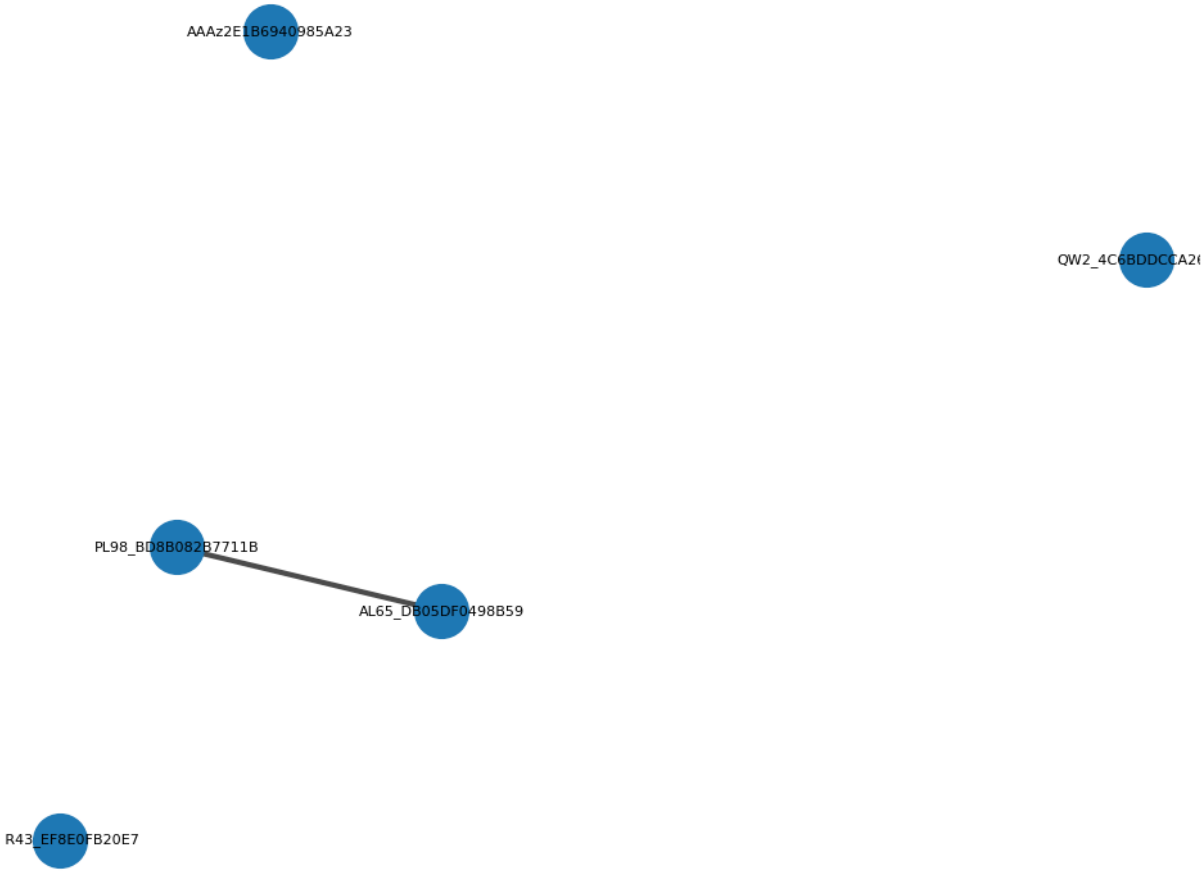

Familia 3 strings umbral 0.95

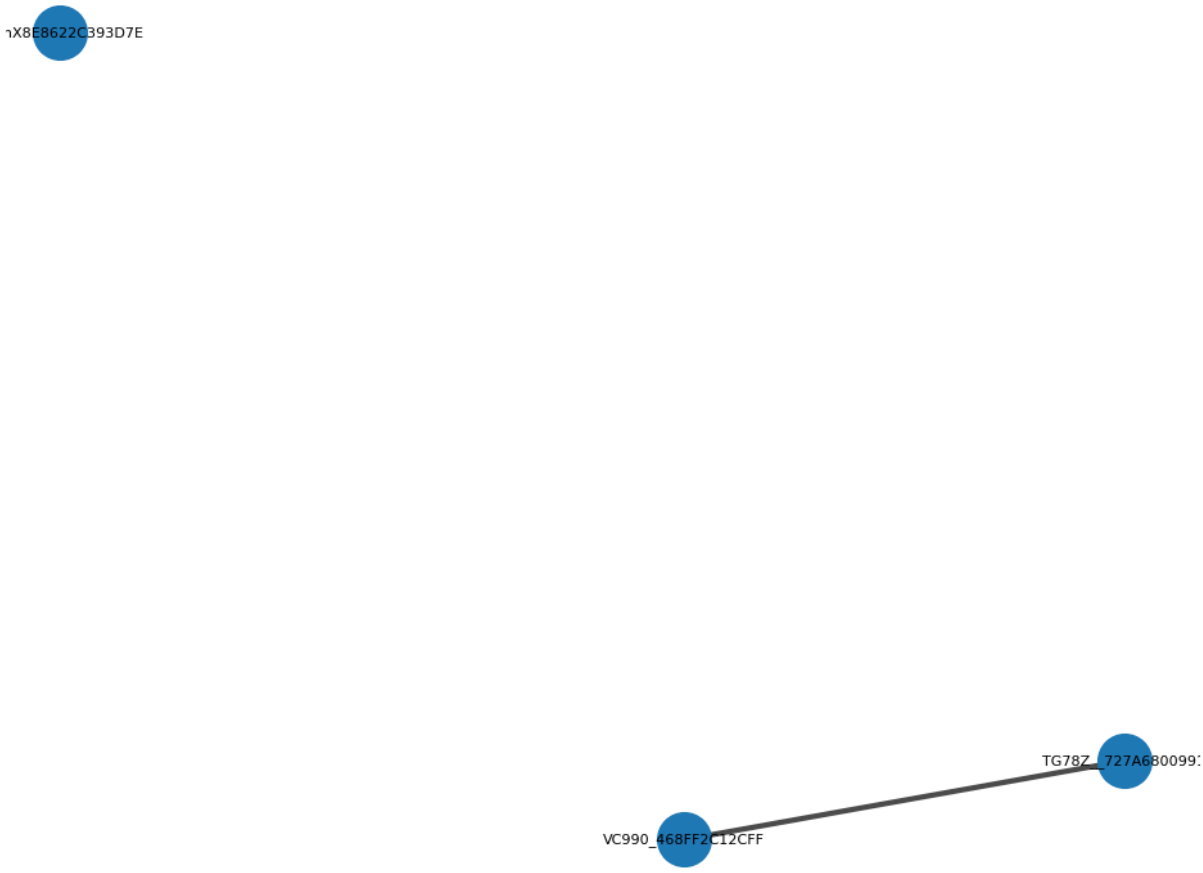

Familia 4 strings umbral 0.95

Grafo completo funciones umbral 0.6

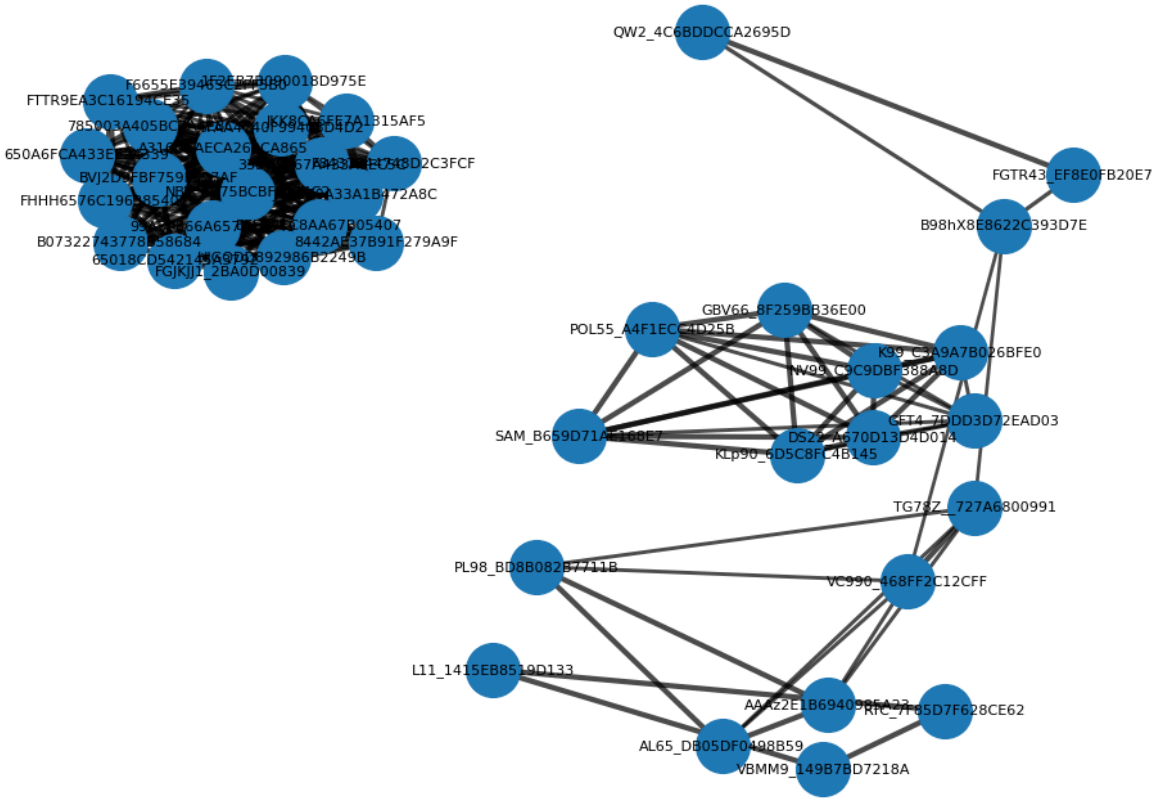

Familia 0 funciones umbral 0.6

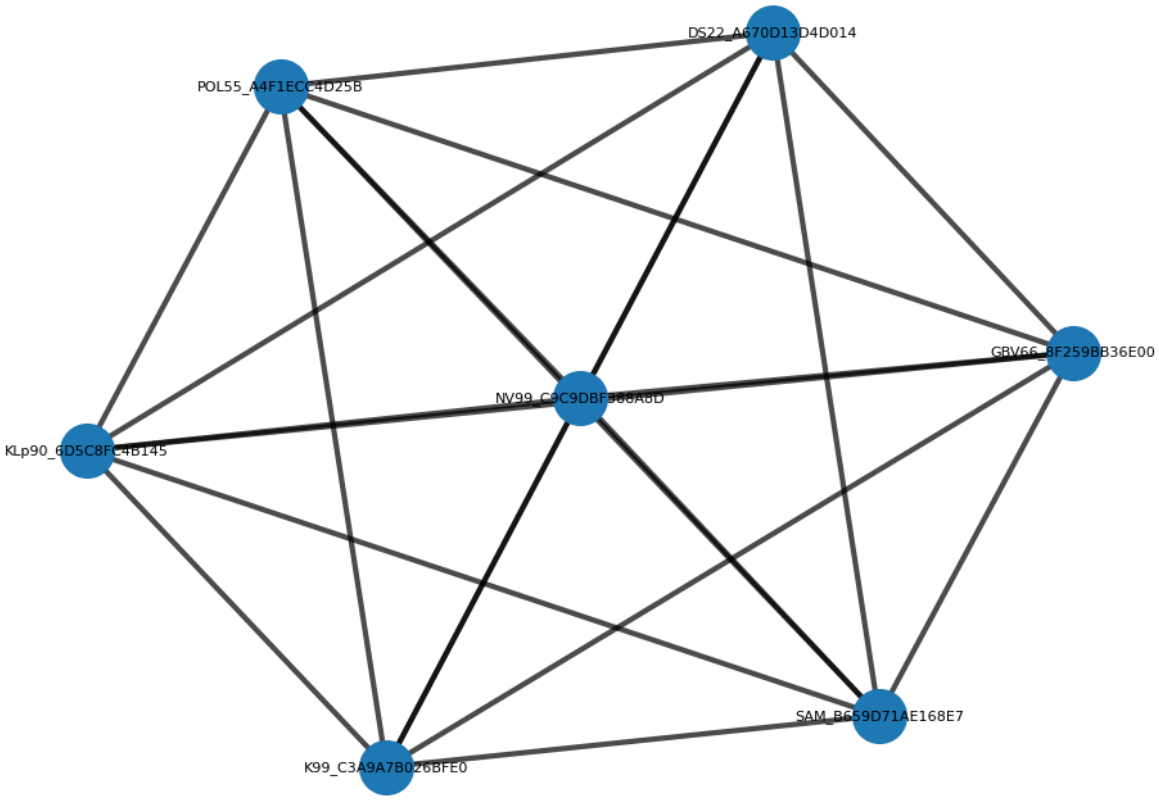

Familia 1 funciones umbral 0.6

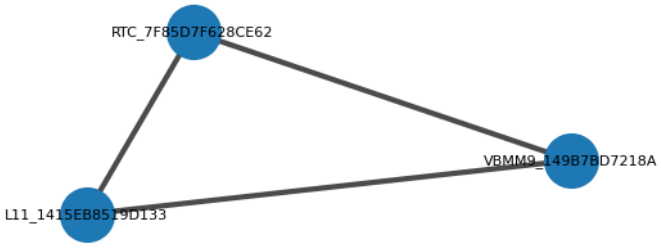

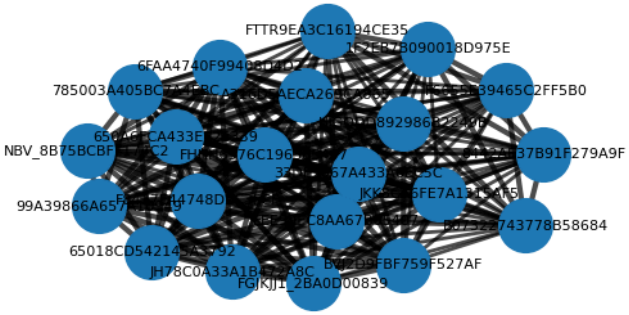

Familia 2 funciones umbral 0.6

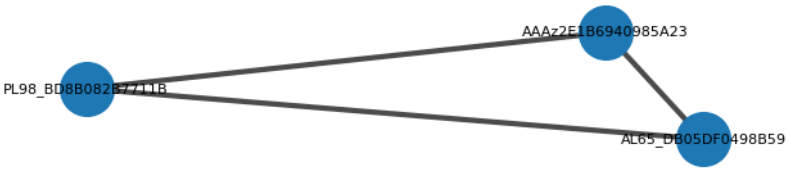

Familia 3 funciones umbral 0.6

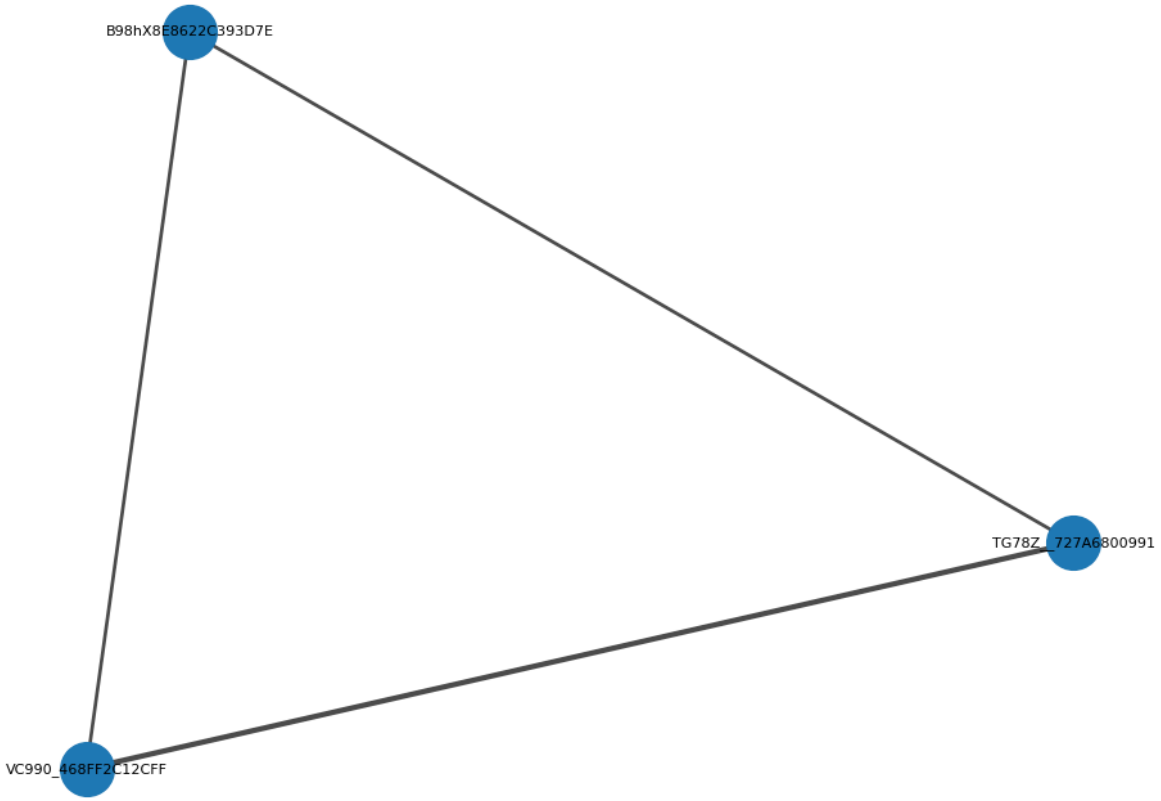

Familia 4 funciones umbral 0.6

Grafo completo funciones umbral 0.8

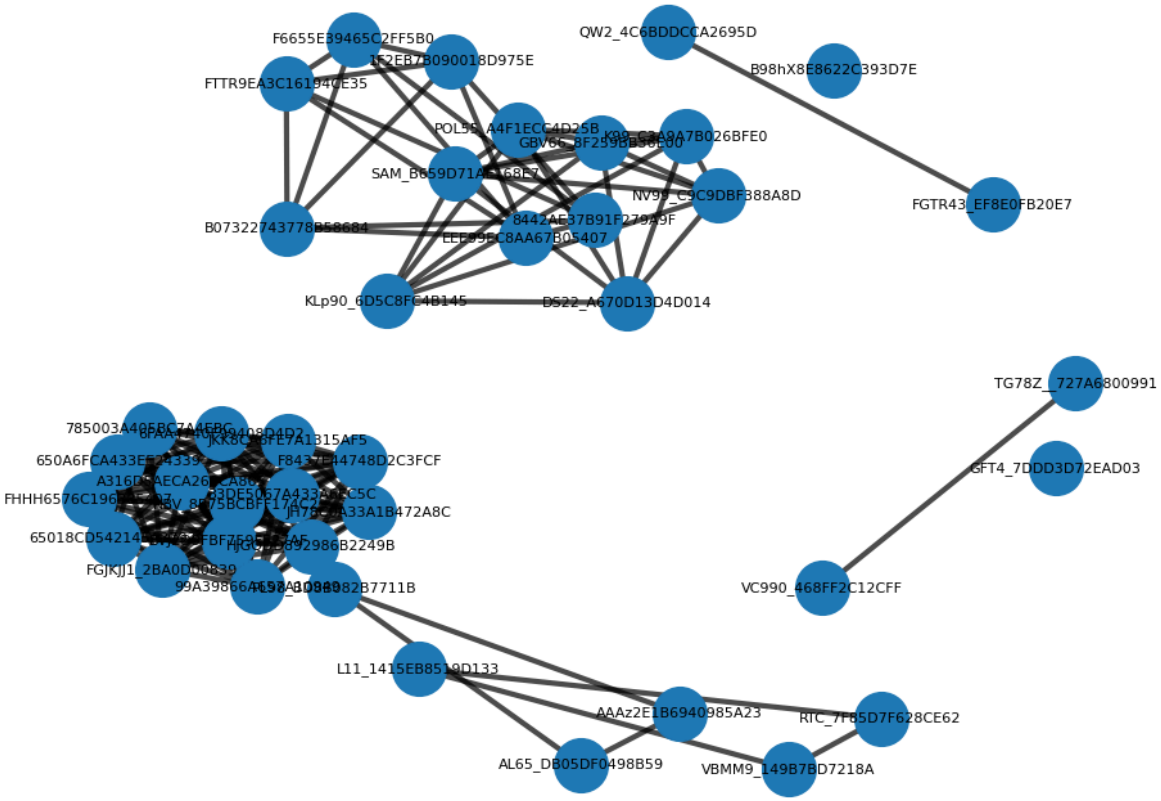

Familia 0 funciones umbral 0.8

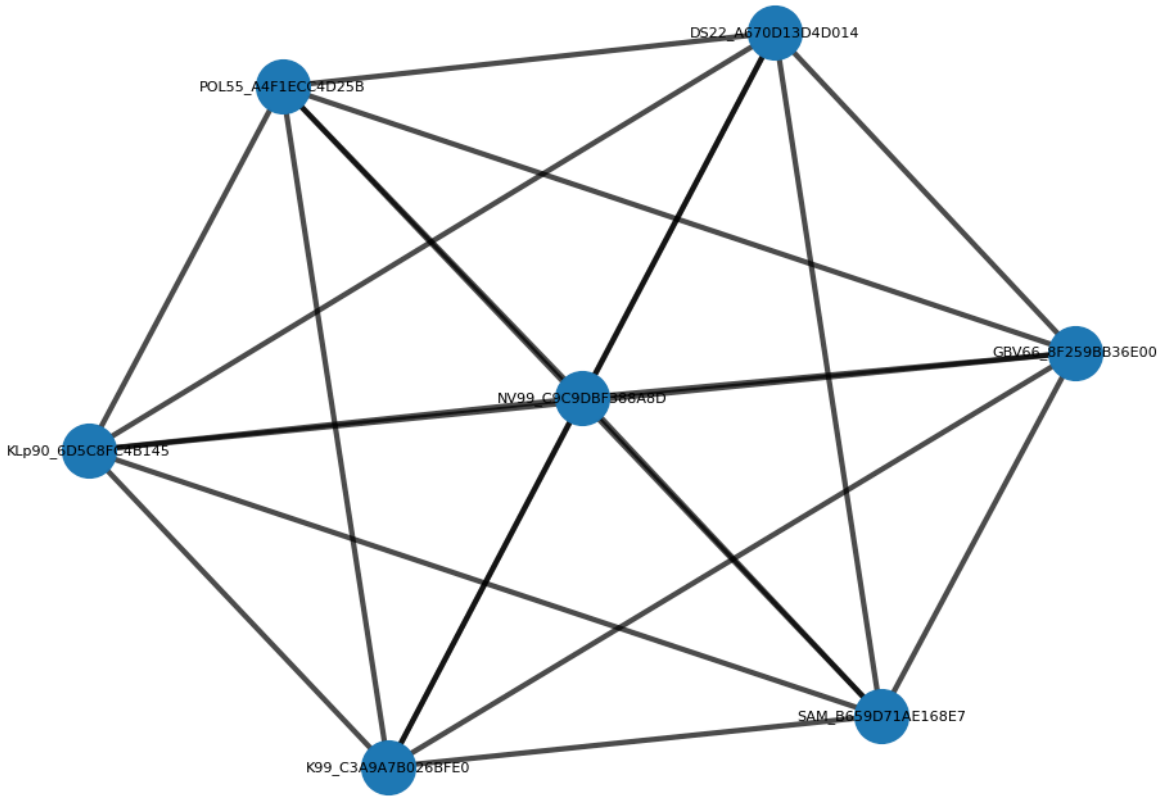

Familia 1 funciones umbral 0.8

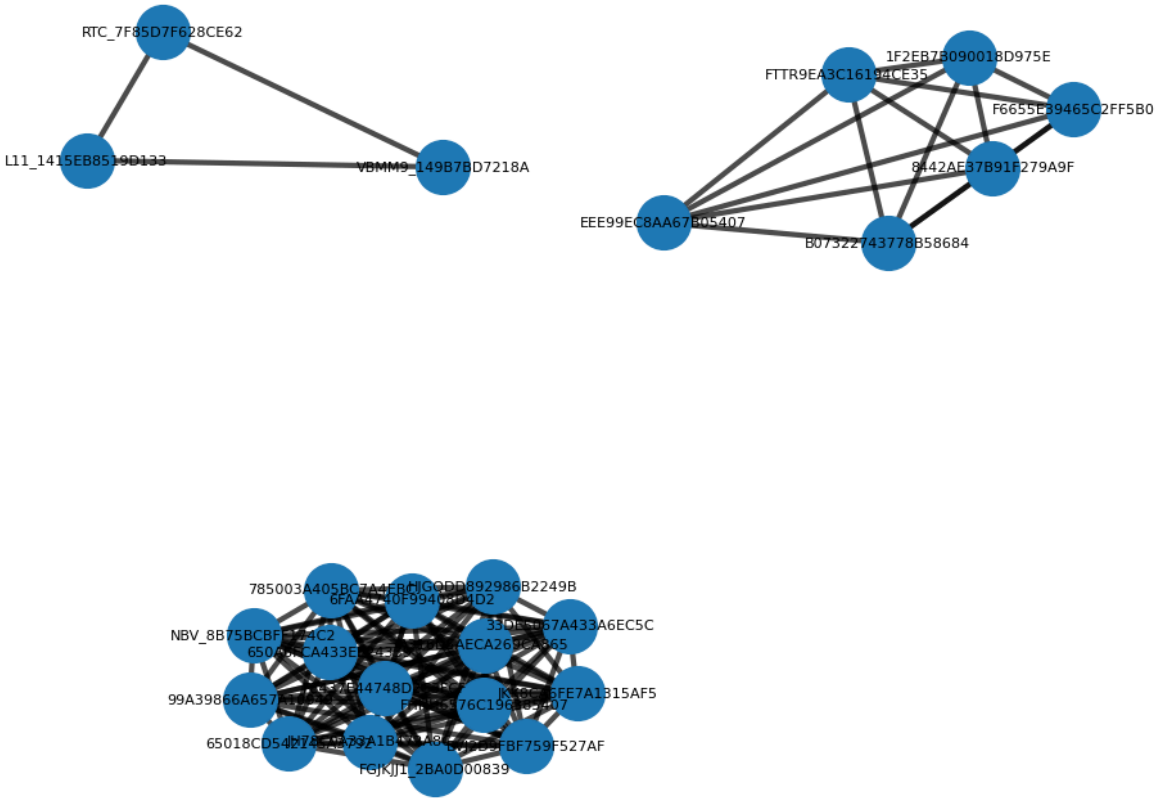

Familia 2 funciones umbral 0.8

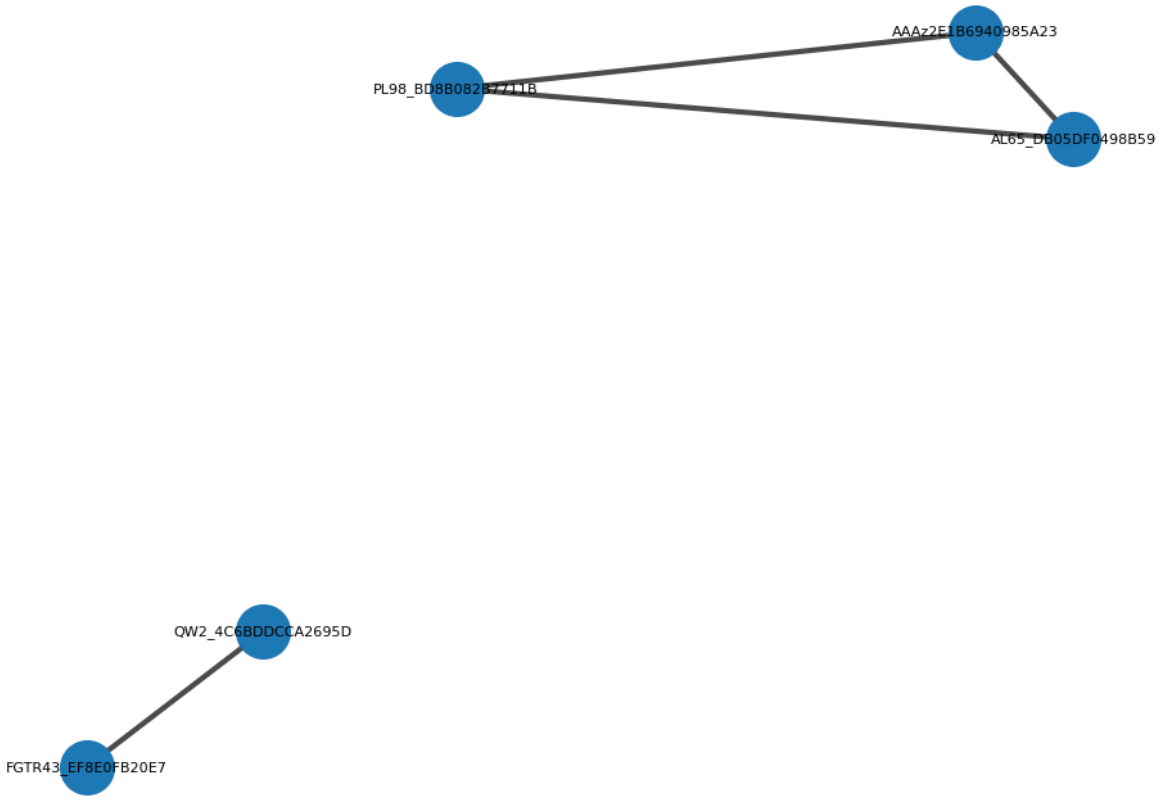

Familia 3 funciones umbral 0.8

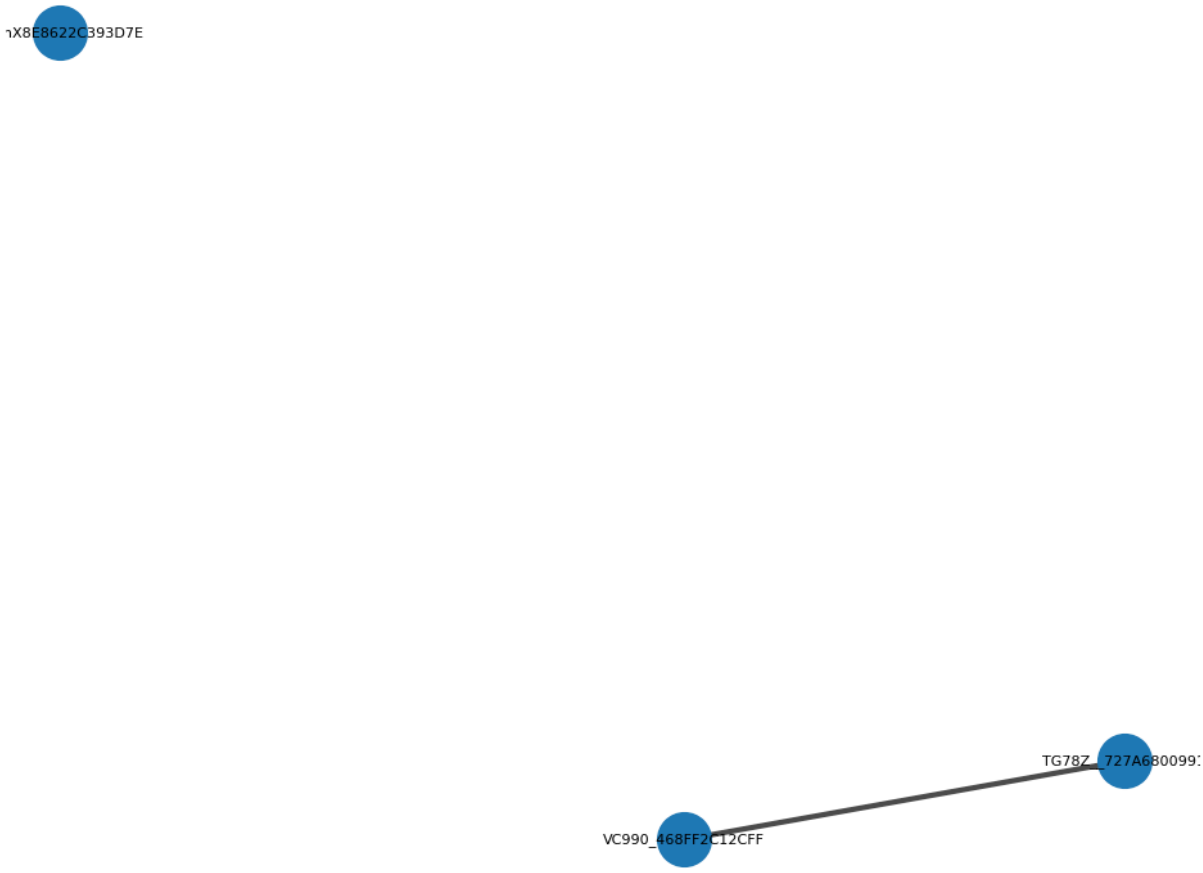

Familia 4 funciones umbral 0.8

Grafo completo funciones umbral 0.95

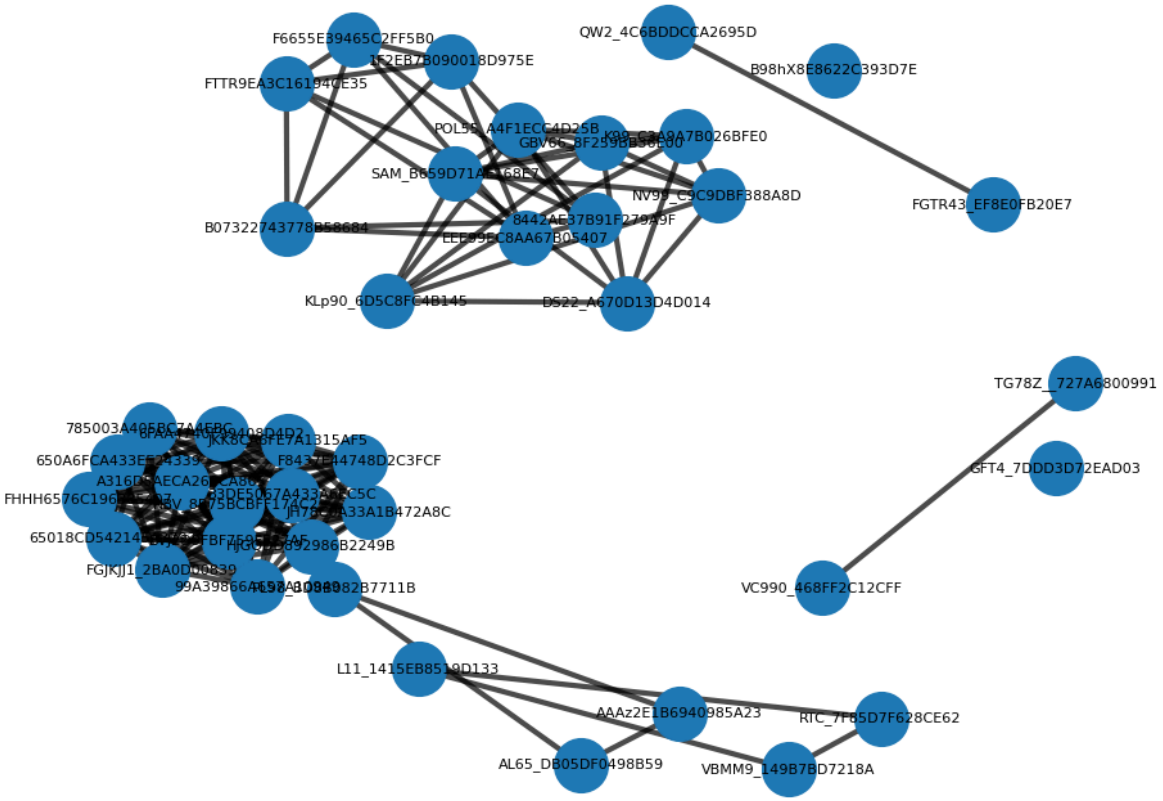

Familia 0 funciones umbral 0.95

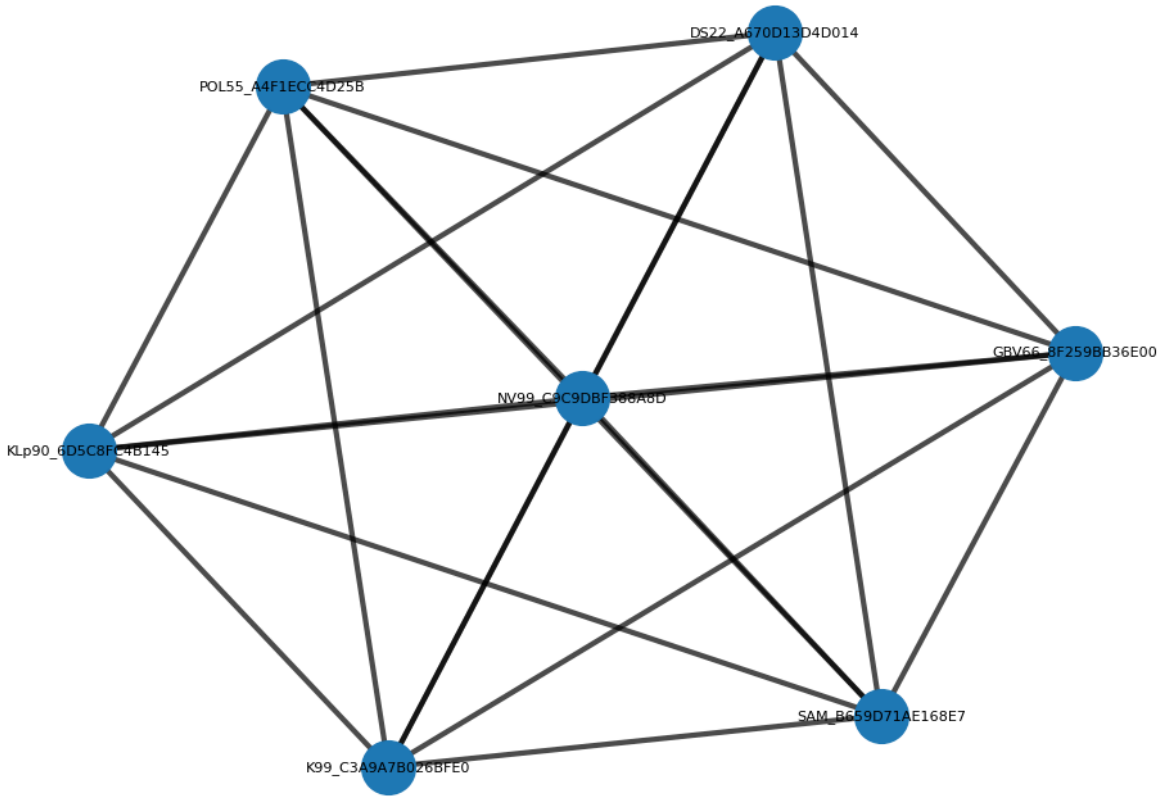

Familia 1 funciones umbral 0.95

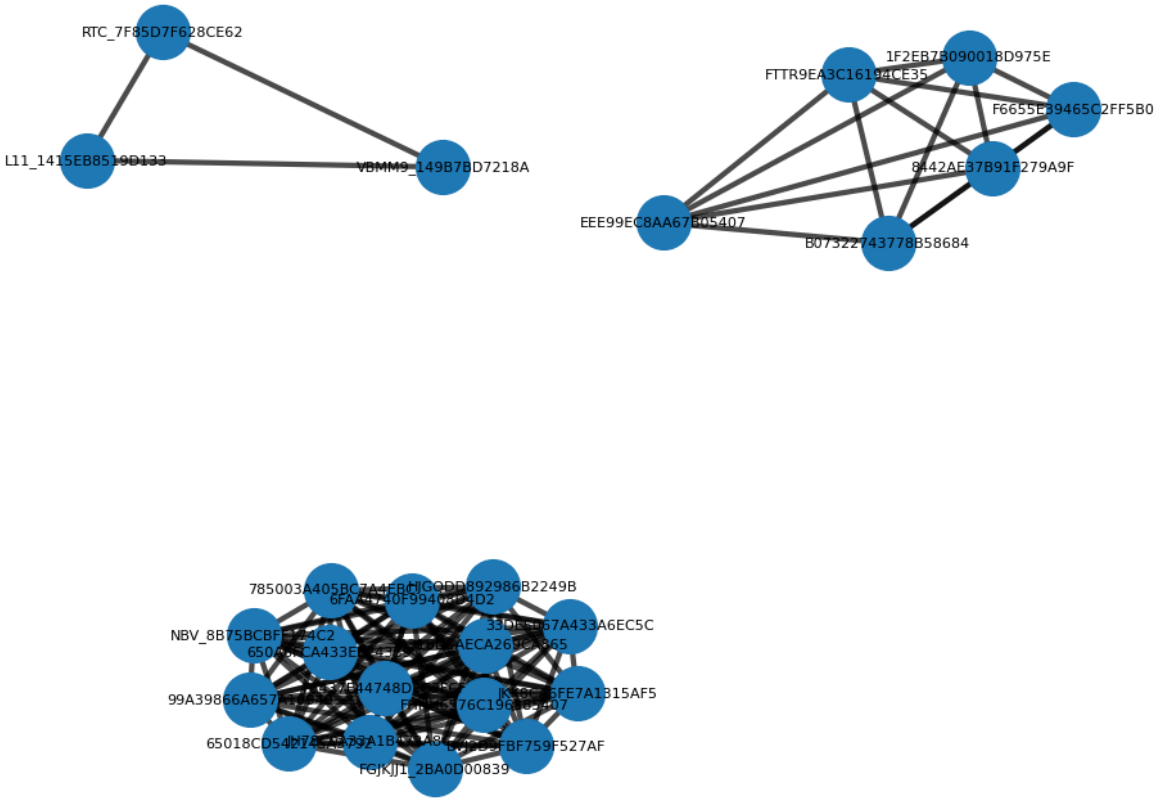

Familia 2 funciones umbral 0.95

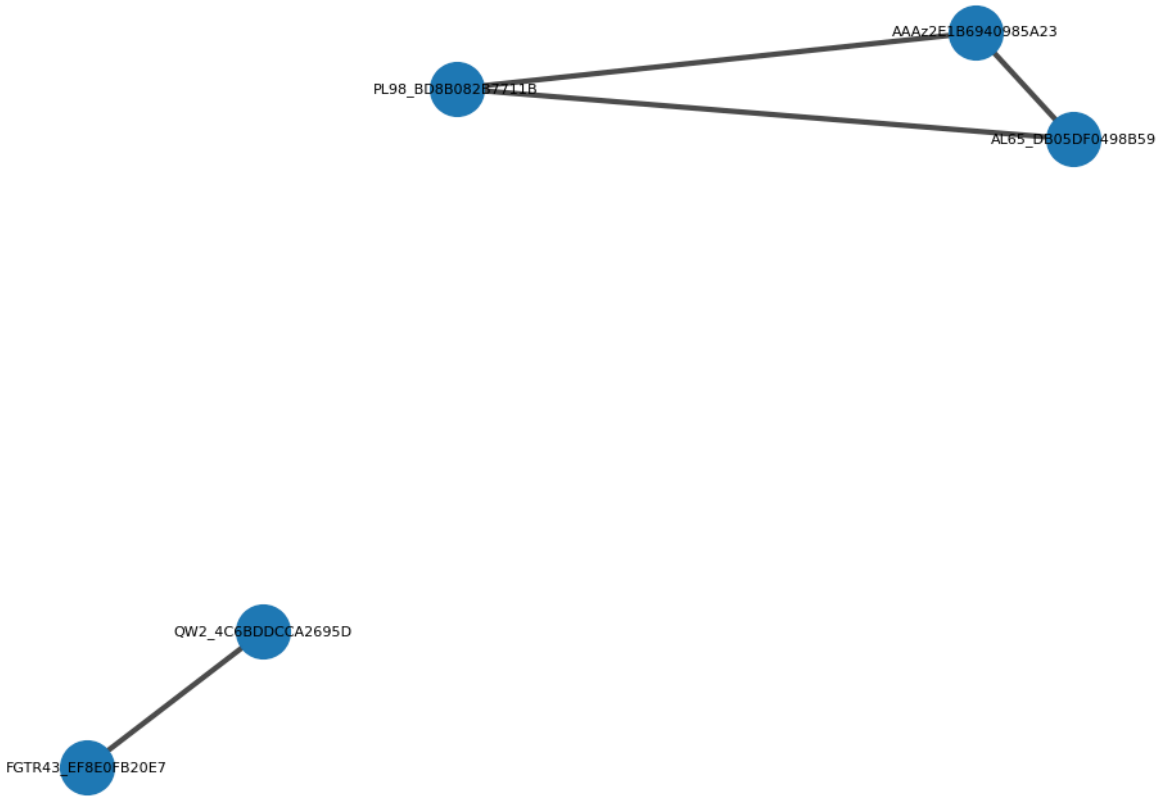

Familia 3 funciones umbral 0.95

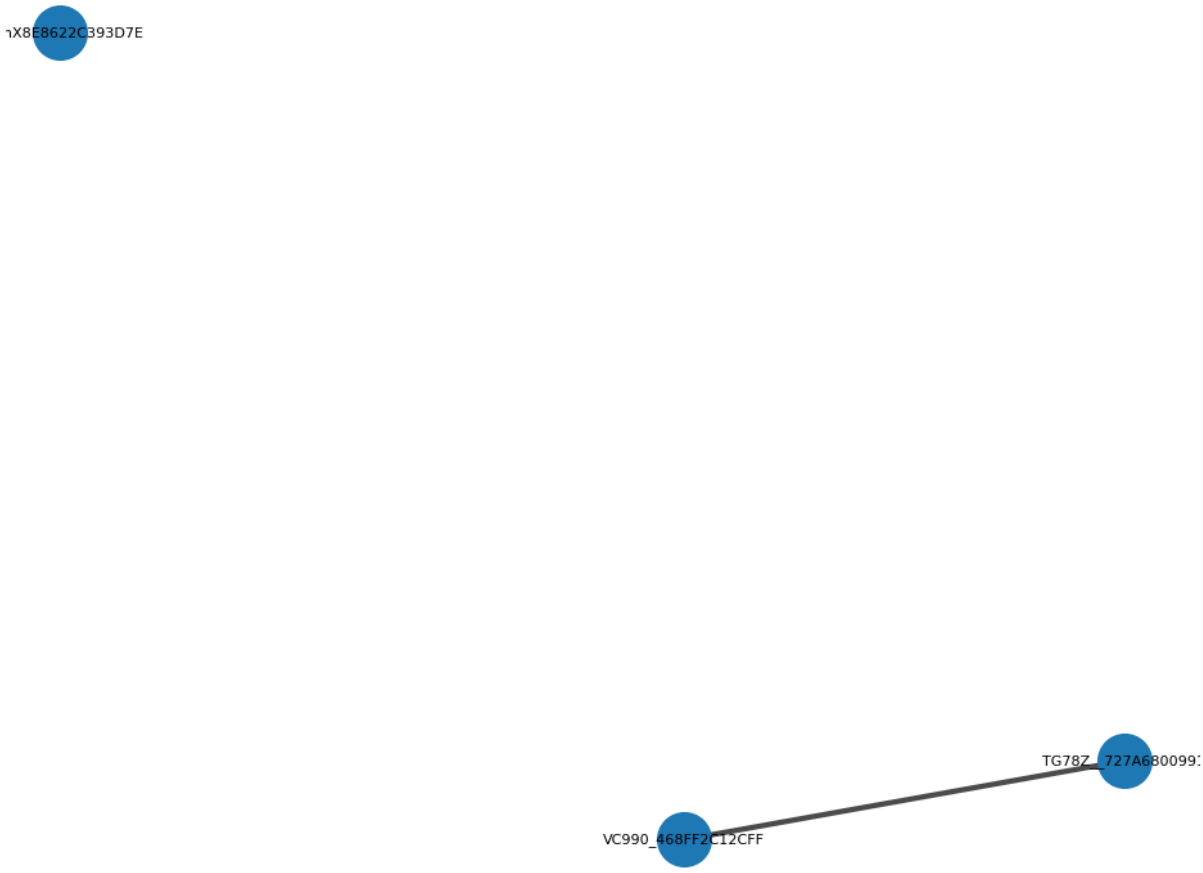

Familia 4 funciones umbral 0.95

```
Grafos generados en: ./salidasLab3/grafos
```

Resumen de familias encontradas y comparacion de caracteristicas

In [ ]:
```
# se muestra el tamanio de familias encontardas
def resumirFamilias(dataframe: pd.DataFrame) -> pd.DataFrame:
    resumen = (
        dataframe.groupby("clusterFinal")
        .agg(
            cantidadMuestras=("nombreArchivo", "count"),
            tamanoPromedio=("tamanoBytes", "mean"),
            stringsPromedio=("numeroStrings", "mean"),
            importsPromedio=("numeroImports", "mean"),
            entropiaPromedio=("entropiaArchivo", "mean"),
            empaquetados=("empaquetadoHeuristico", "sum"),
        )
        .reset_index()
        .sort_values("clusterFinal")
    )
    return resumen


# se compara si strings o funciones conectan mas por promedio de similitud
def compararCaracteristicas(dataframeStrings: pd.DataFrame, dataframeFuncior
    filas = [{
        "caracteristica": "strings",
        "promedioSimilitud": float(dataframeStrings["similitud"].mean()) if
        "medianaSimilitud": float(dataframeStrings["similitud"].median()) if
    }, {
        "caracteristica": "funciones",
        "promedioSimilitud": float(dataframeFunciones["similitud"].mean()) i
        "medianaSimilitud": float(dataframeFunciones["similitud"].median())
    }]
    return pd.DataFrame(filas)


DfResumenFamilias = resumirFamilias(DfDataset)
DfComparacionCaracteristicas = compararCaracteristicas(DfSimStrings, DfSimFu
RutaResumenFamilias = os.path.join(RutaTablas, "resumenFamilias.csv")
RutaComparacionCaracteristicas = os.path.join(RutaTablas, "comparacionCaract
DfResumenFamilias.to_csv(RutaResumenFamilias, index=False, encoding="utf-8")
DfComparacionCaracteristicas.to_csv(RutaComparacionCaracteristicas, index=Fa

print("Resumen de familias")
display(DfResumenFamilias)
print("Comparacion de strings vs funciones")
display(DfComparacionCaracteristicas)
```

```
Resumen de familias
```

	clusterFinal	cantidadMuestras	tamanoPromedio	stringsPromedio	importsP
0	0	7	15360.0	252.000000	8
1	1	24	6592.0	133.916667	
2	2	5	324915.2	5266.600000	1
3	3	3	327168.0	5347.000000	1
4	4	1	16896.0	254.000000	8

```
Comparacion de strings vs funciones
```

	caracteristica	promedioSimilitud	medianaSimilitud
0	strings	0.182415	0.053073
1	funciones	0.380391	0.250000

Reporte final con respuestas del analisis

Proceso realizado

1. Creacion del dataset

Se construyo un dataset. Para cada muestra se extrajeron strings ASCII, funciones importadas, dlls, secciones y metadatos PE como tamano, numero de secciones, imports, recursos, entropia y heuristica de empaquetado. El dataset final contiene 40 muestras.

2. Preprocesamiento

Se aplico preprocesamiento mixto. Las columnas numericas fueron escaladas con StandardScaler y las columnas textuales fueron vectorizadas con TF IDF usando un documento combinado de strings, funciones, dlls, secciones y rasgos de cabecera PE. Esto permitio que los algoritmos no supervisados trabajaran con datos heterogeneos.

3. KMeans

El mayor coeficiente de silhouette para KMeans fue 0.7619 con K=5.

4. KMedoids

El mayor coeficiente de silhouette para KMedoids fue 0.7619 con K=5.

5. Metodo del codo contra silhouette

Imagenes se encuentran en su carpeta correspondeinte. Los valores con mejor silhouette fueron K=5 para KMeans y K=5 para KMedoids.

6. Numero estimado de familias

Segun el mejor algoritmo final, se selecciono KMeans con K=5. Por lo tanto, la mejor estimacion de familias de malware en este conjunto es 5.

7. Embeddings Gemini

Los embeddings de Gemini se comparan visualmente con la grafica de 2D de embeddings y la grafica 2D del algoritmo final. Los grupos de puntos aparecen cercanos entre si en ambas visualizaciones, por lo que hay una coincidencia razonable entre embeddings y clustering clasico.

8. Analisis de strings y funciones

Se calcularon similitudes de Jaccard para strings y funciones. El promedio de similitud para strings fue 0.1824. El promedio de similitud para funciones fue 0.3804. Esto ayuda a determinar cual rasgo conecta mejor a los ejemplares dentro de una familia.

Comparacion de modelos

Al comparar KMeans y KMedoids, ambos algoritmos dan resultados muy parecidos y llegan a la misma conclusion, el mejor numero de clusters es 5. Los dos alcanzan exactamente el mismo coeficiente de Silhouette maximo, 0.761, cuando K=5, lo cual da mucha confianza en que esa cantidad representa las familias presentes en el conjunto de malware. En general, KMeans y KMedoids coinciden en la estructura global de los datos, pero KMeans fue elegido como modelo final porque mantiene el mismo mejor resultado y ademas es mas simple y directo para trabajar en este caso. Tambien se observa que la sseparacion entre grupos mejora bastante de K=2 a K=5, y luego empieza a perder estabilidad, por lo que 5 clusters parece ser el punto mas equilibrado. En la parte de similitud, las llamadas a funciones reflejan mejor las relaciones entre muestras que los strings, ya que su similitud promedio es mayor. En fin, los resultados de particionamiento, embeddings y similitud apuntan a una estructura consistente de 5 familias de malware.

1. Para ambos algoritmos de particionamiento, ¿para qué número de clústeres se obtiene el coeficiente de Silhouette mas alto?

Para ambos algoritmos, KMeans y KMedoids, el coeficiente de Silhouette mas alto se obtiene con K=5. En ambos casos el valor máximo fue 0.761. Esto dice

que, entre los valores probados, 5 clusters es la mejor opción para separar las muestras de manera mas clara y coherente.

2. Para ambos algoritmos de particionamiento, ¿en qué medida coincide el coeficiente de Silhouette con el método del codo?

Si coinciden. Aunque el metodo del codo se necesita una inerpretacion visual, en ambos algoritmos se observa una reduccion fuerte del error hasta llegar cerca de K=5, y a partir de ahi la mejora ya no es tan marcada. Al mismo tiempo, el coeficiente de Silhouette también alcanza su mejor valor justamente en K=5. Por lo tanto, ambos criterios apuntan hacia la misma conclusion.

3. Según los resultados obtenidos de ambos algoritmos de particionamiento, ¿cuántas familias cree que existen entre los ejemplares de malware proporcionados?

Con base en los resultados de ambos algoritmos, la mejor estimación es que existen 5 familias de malware en el conjunto analizado. Esta conclusion se basa en que KMeans y KMedoids coinciden en el mismo valor de K y en el mismo mejor coeficiente de Silhouette.

4. ¿En qué medida es similar el análisis de la agrupación de los embeddings de Gemini contra los resultados de los algoritmos de particionamiento?

El analisis con embeddings de Gemini es parecido de manera general a los resultados de los algoritmos de particionamiento, porque también permite observar una agrupacion de las muestras en conjuntos diferenciados. No necesariamente la separacion visual es a la de KMeans o KMedoids, pero si sirve como una validacion adicional de que el dataset tiene alguna estructura interna y que las muestras no estan distribuidas al azar. En otras palabras, Gemini refuerza la idea de que si existen grupos naturales dentro del conjunto, y esos grupos son compatibles con el calculo de 5 familias.

5. ¿En qué medida coincide el análisis de similitud con las familias encontradas utilizando los algoritmos de partición, para ambas características, strings y llamadas a las funciones?

El analisis de similitud coincide de forma parcial pero util con las familias encontradas por los algoritmos de particion. En las dos caracteristicas se observan relaciones entre muestras de una misma familia, pero las llamadas a las funciones coinciden mejor con los clusters que los strings. Esto se nota porque la similitud promedio en funciones fue 0.38, mientras que en strings fue 0.182415. Eso lo que dice es que las funciones importadas o llamadas conservan mejor el comportamiento comun entre muestras de una misma familia, mientras que los strings pueden variar mas por configuracion u ofuscacion. Por eso,

aunque ambas caracteristicas dan datos, las llamadas a las funciones fueron mas consistentes para respaldar las familias encontradas.